JI STUDIO

APPLIED AI · AUTONOMOUS SYSTEMS

# ARCHIVAI

## Искусственный интеллект для исторического архива

Сканы → распознанный текст, структурированные поля, связи между людьми и организациями,
семантический поиск и проверка человеком. На открытых моделях, на вашем оборудовании.

КЛИЕНТ

Государственный архив

ПРОДУКТ

ArchivAI · v1

РАЗВЁРТЫВАНИЕ

On-premise

ДАТА

07 · 2026

01 ЗАДАЧА

# ЧТО МЕШАЕТ РАБОТАТЬ С ФОНДОМ СЕГОДНЯ

**01** **Документы не ищутся**

Скан — это картинка. Найти дело можно только по описи и памяти сотрудника.

**02** **Связи не видны**

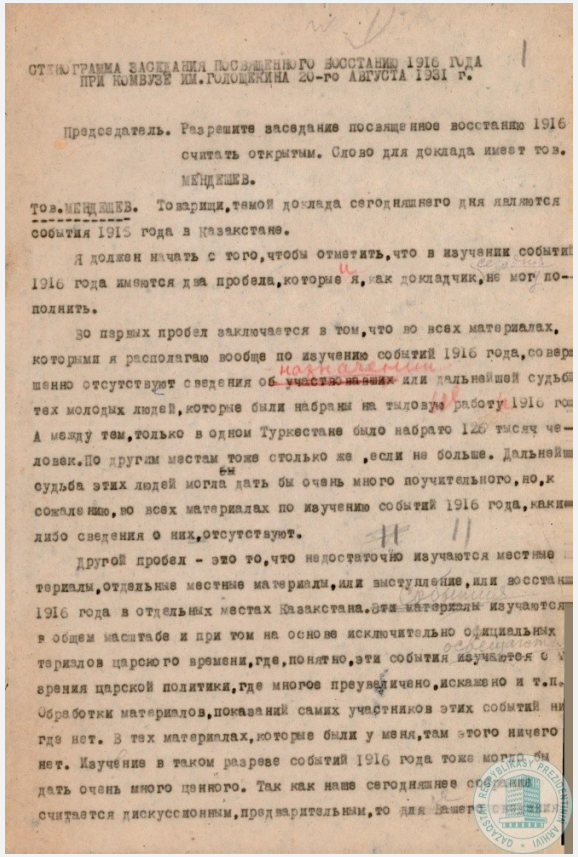
Кто с кем переписывался, где упоминается человек — собирается вручную, месяцами.

**03** **Ручная опись**

Тип, дата, отправитель, получатель, персоналии — всё вносится руками.

**04** **Данные должны остаться у вас**

Облачные сервисы и передача фонда наружу — неприемлемы.



СТЕНОГРАММА ЗАСЕДАНИЯ ПОСВЯЩЕННОГО ВОССТАНИЮ 1916 ГОДА
ПРИ КОМВУЗЕ ИМ.ГОЛОЩЕКИНА 20-го АВГУСТА 1931 г.

Председатель. Разрешите заседание посвященное восстанию 1916 считать открытым. Слово для доклада имеет тов. МЕНДИШЕВ.

Тов.МЕНДИШЕВ. Товарищи,темой доклада сегодняшнего дня являются события 1916 года в Казакстане.

Я должен начать с того,чтобы отметить,что в изучении событий 1916 года имеются два пробела,которые я,как докладчик,не мог пополнить.

Во первых пробел заключается в том,что во всех материалах, которыми я располагаю вообще по изучению событий 1916 года,совершенно отсутствуют сведения об участниках или дальнейшей судьбе тех молодых людей,которые были набраны на тыловую работу 1916 года. А между тем,только в одном Туркестане было набрато 125 тысяч человек.По другим местам тоже столько же ,если не больше. Дальнейшая судьба этих людей могла дать бы очень много поучительного,но,к сожалению,во всех материалах по изучению событий 1916 года,какие либо сведения о них,отсутствуют.

Другой пробел - это то,что недостаточно изучаются местные материалы,отдельные местные материалы,или выступление,или восстание 1916 года в отдельных местах Казакстана.Эти материалы изучаются в общем масштабе и при том на основе исключительно официальных материалов царского времени,где,понятно,эти события изучаются с точки зрения царской политики,где многое преувеличено,искажено и т.п. Обработки материалов,показаний самих участников этих событий нигде нет. В тех материалах,которые были у меня,там этого ничего нет. Изучение в таком разрезе событий 1916 года тоже могло бы дать очень много ценного. Так как наше сегодняшнее собрание считается дискуссионным,предварительным,то для нашего

Типовой лист фонда: машинопись, правки от руки, печать, пожелтевшая бумага

02 КАК ЭТО РАБОТАЕТ

# ОТ СКАНА ДО ЗНАНИЯ — ЗА ОДИН ПРОХОД

**01 Приём**
загрузка или забор из вашего хранилища

→

**02 Распознавание**
печатный и рукописный текст, RU + KZ

→

**03 Извлечение**
тип, дата, отправитель, получатель, резюме

→

**04 Сущности**
люди, организации, места, даты, количества

→

**05 Индексация**
поиск по смыслу, а не по буквам

→

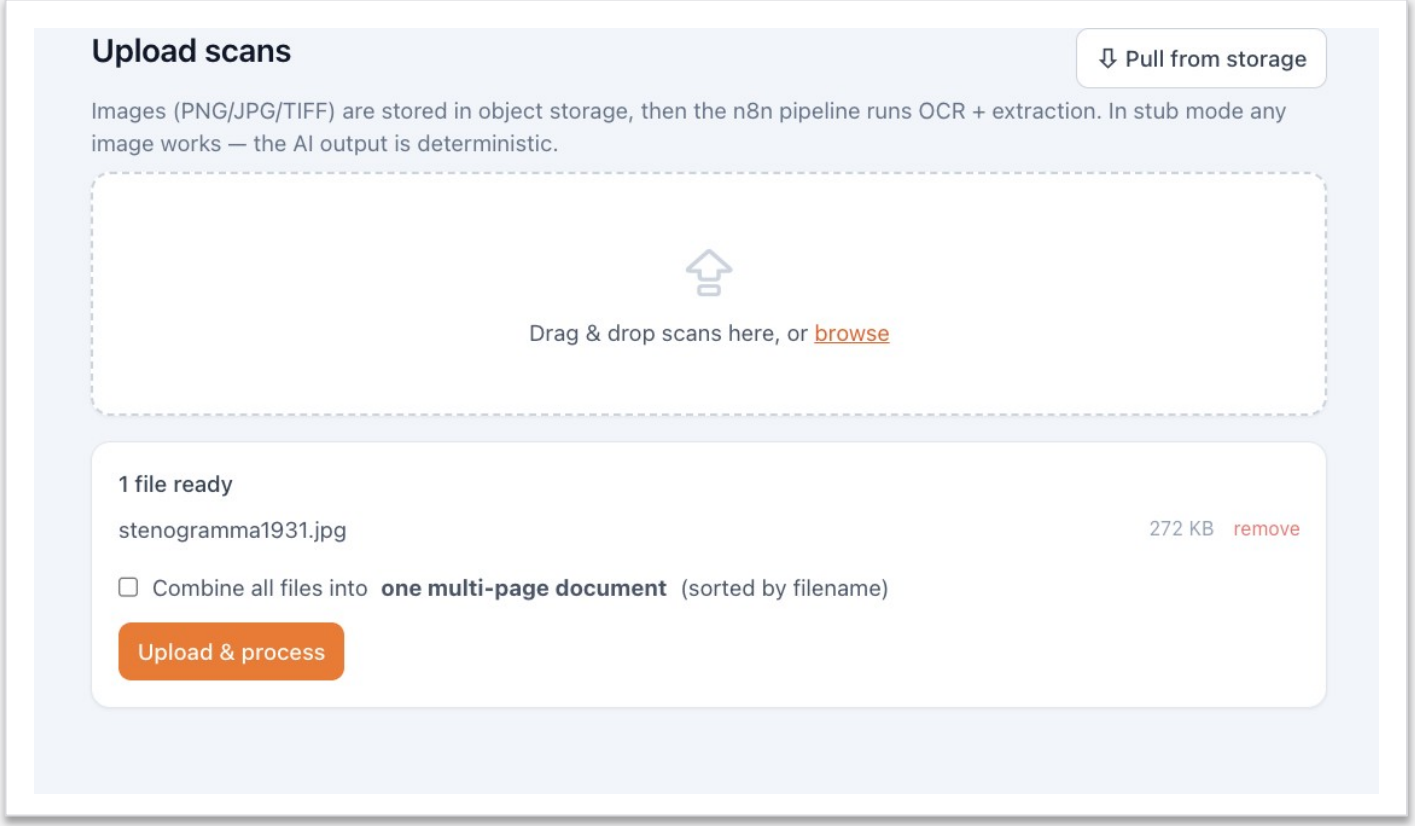
**06 Проверка**
правка человеком и статус «проверено»

## Каждый этап — отдельный видимый процесс

Модель распознавания, правила извлечения, набор типов документов можно заменить или дополнить без переписывания системы. Ничего не «зашито» в чёрный ящик: любой шаг открывается, повторяется и настраивается под ваш фонд.

03 ПРИЁМ ДОКУМЕНТОВ

# ЗАГРУЗКА И ЗАБОР ИЗ ХРАНИЛИЩА




— Перетащите сканы в окно — или соберите многостраничное дело из нескольких файлов

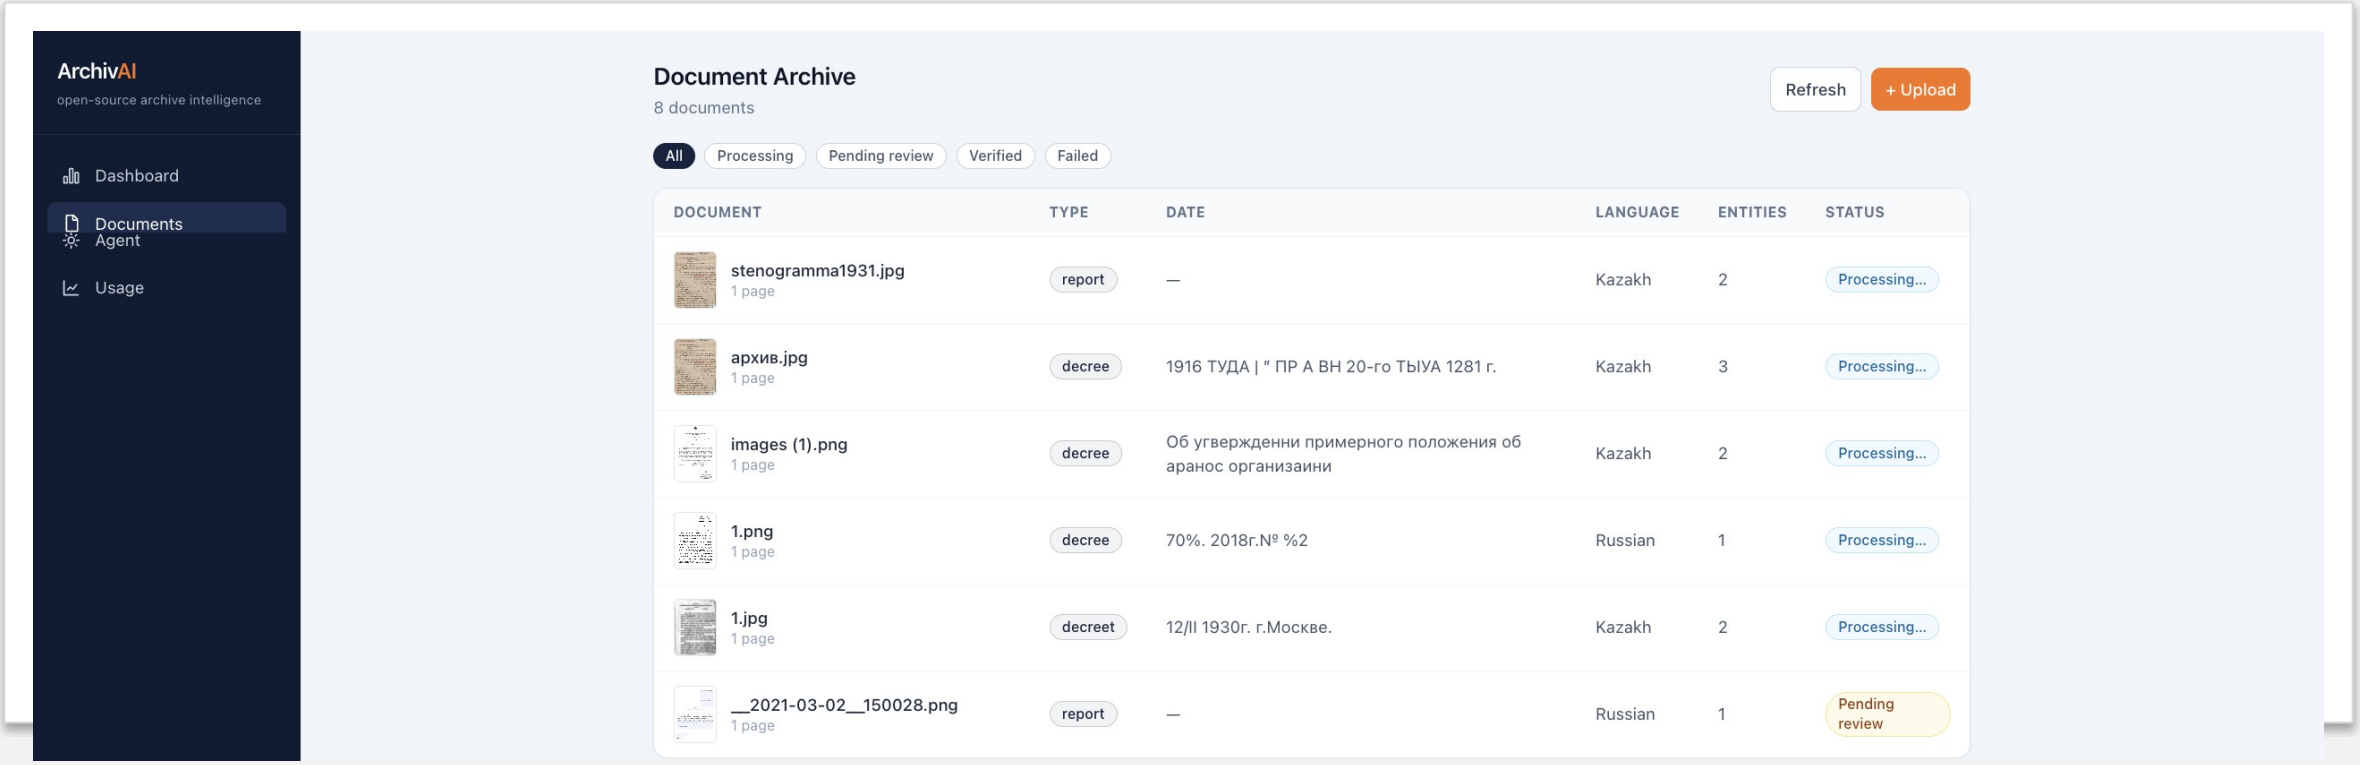
— «Забрать из хранилища»: система сама берёт новые файлы — 50–100+ документов за раз

— Автоматический забор каждые 5 минут: положили сканы в папку — они появились в архиве обработанными

— Повторная заливка не создаёт дублей: уже обработанные файлы пропускаются

04 АРХИВ ДОКУМЕНТОВ

# ВЕСЬ ФОНД — В ОДНОЙ ТАБЛИЦЕ




## Статусы обработки

обрабатывается · на проверке · проверено · ошибка

## Фильтры

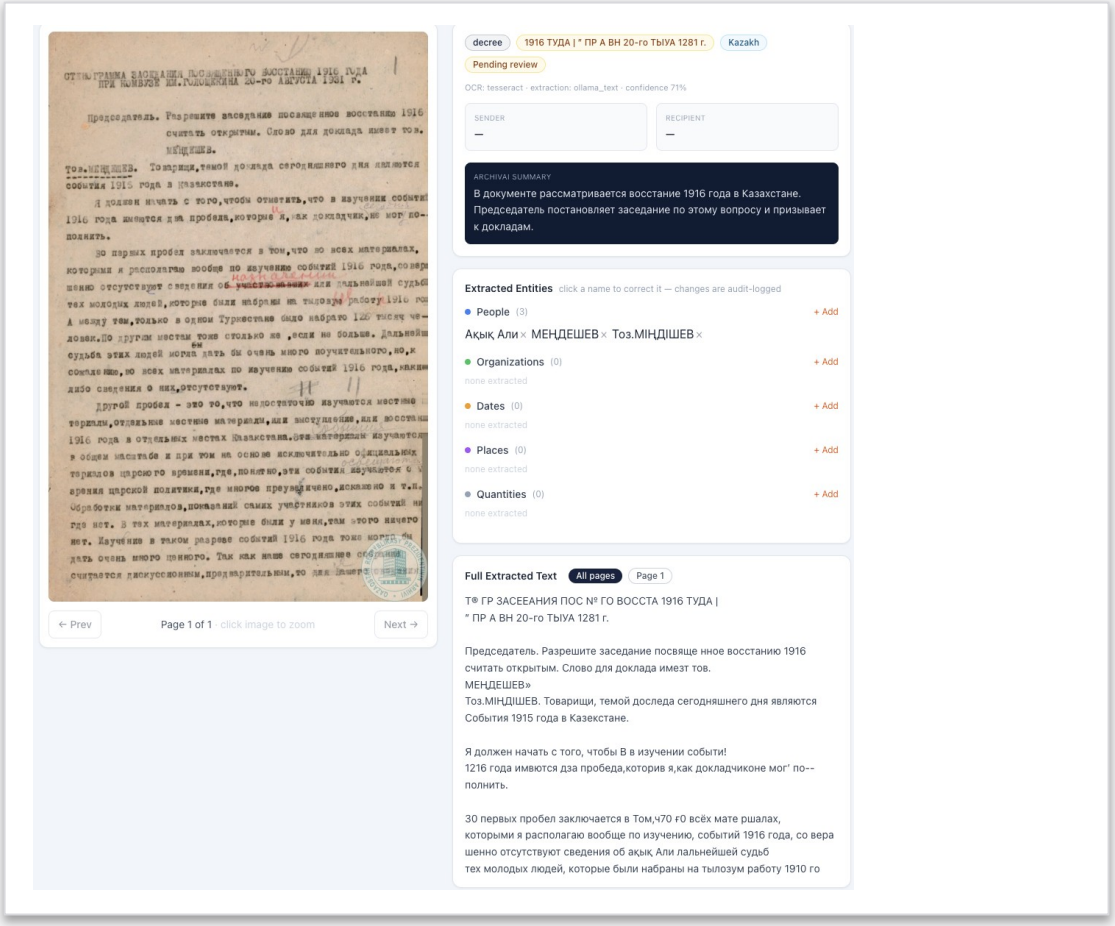
по типу, языку, статусу, дате документа

## Миниатюры

виден сам скан, а не только имя файла

05 КАРТОЧКА ДОКУМЕНТА

# СКАН СЛЕВА — ИЗВЛЕЧЁННЫЕ ДАННЫЕ СПРАВА




## Тип, дата, язык

классификация по вашему справочнику типов

## Отправитель и получатель

с должностью и ролью, если они есть в тексте

## Резюме документа

2–4 предложения на русском: суть дела без чтения листа

## Сущности по 5 категориям

люди · организации · места · даты · количества

## Полный текст

постранично и целиком, с источником и уверенностью

06 ПРОВЕРКА И ДОВЕРИЕ

# ПОСЛЕДНЕЕ СЛОВО — ЗА АРХИВИСТОМ

— Любую сущность можно исправить прямо в карточке: опечатка в фамилии, пропущенная организация

— Кнопка «Проверено» переводит документ в доверенный статус

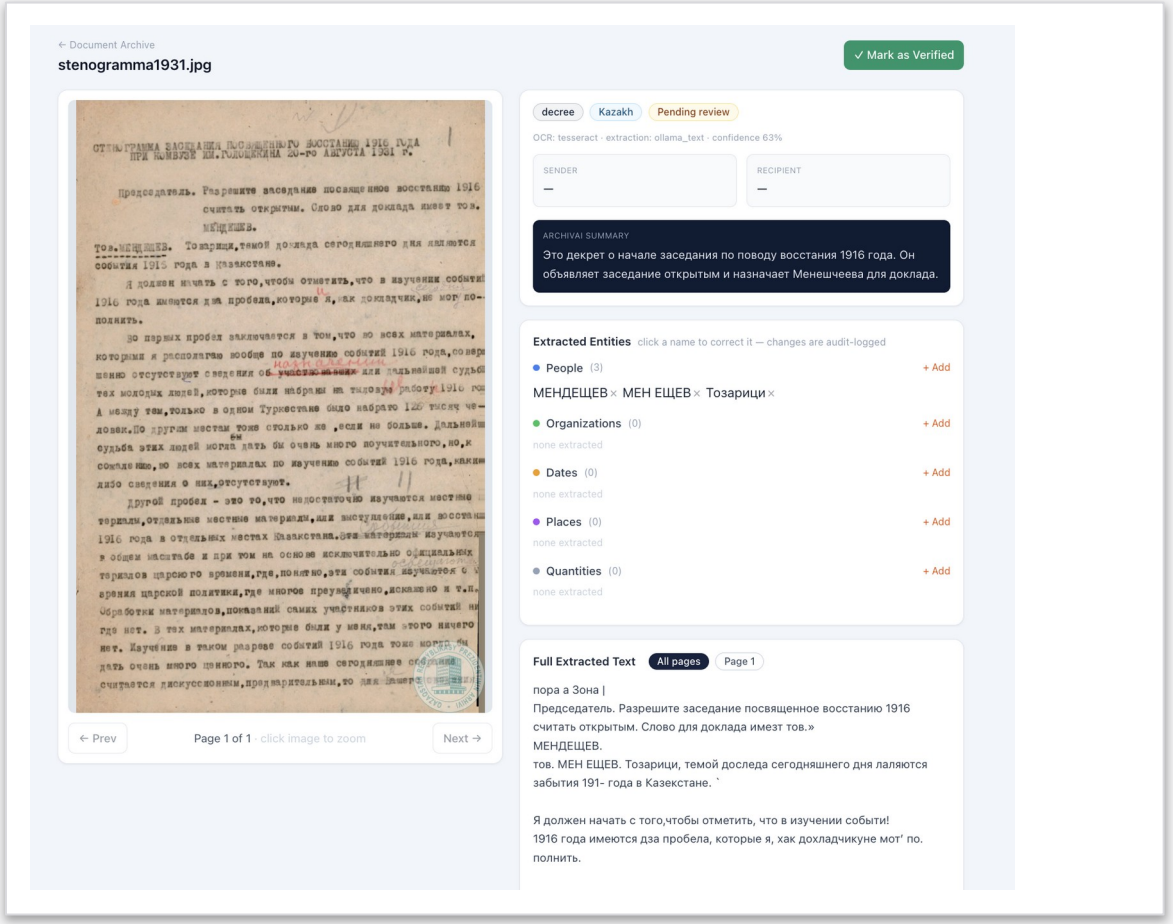
— Каждая правка записывается в журнал: кто, что и когда изменил

— Проверенные документы защищены: массовая переобработка их не трогает

— Исправления накапливаются как эталон — на них система дообучается под ваш фонд

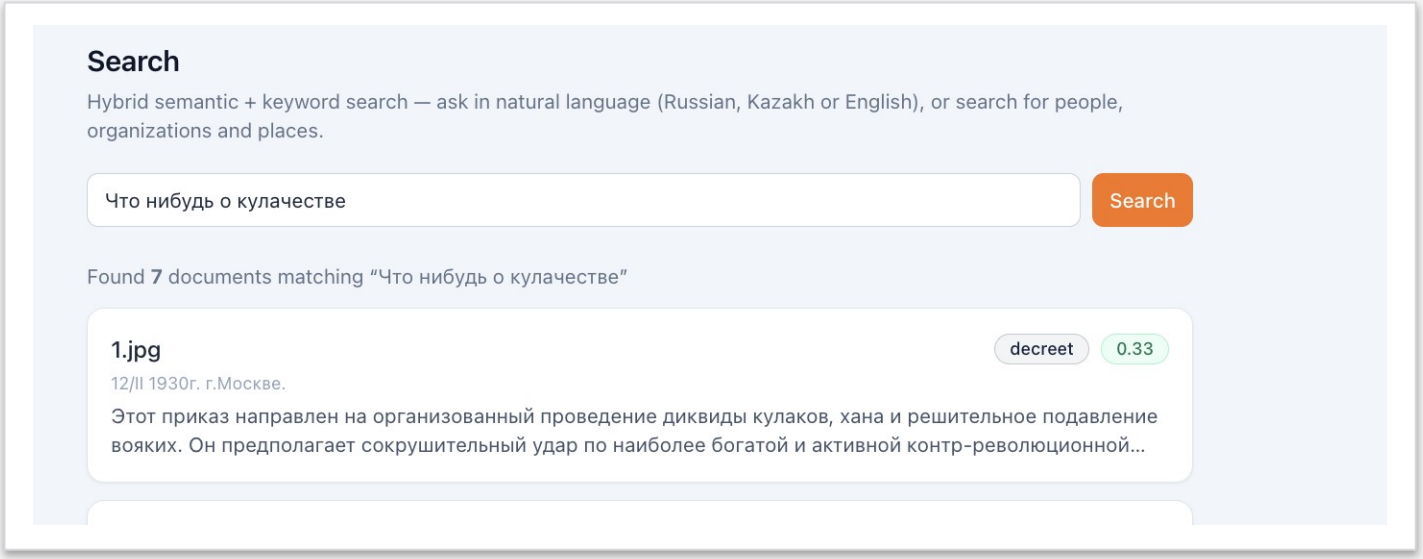
**ИИ ПРЕДЛАГАЕТ — ЧЕЛОВЕК УТВЕРЖДАЕТ**

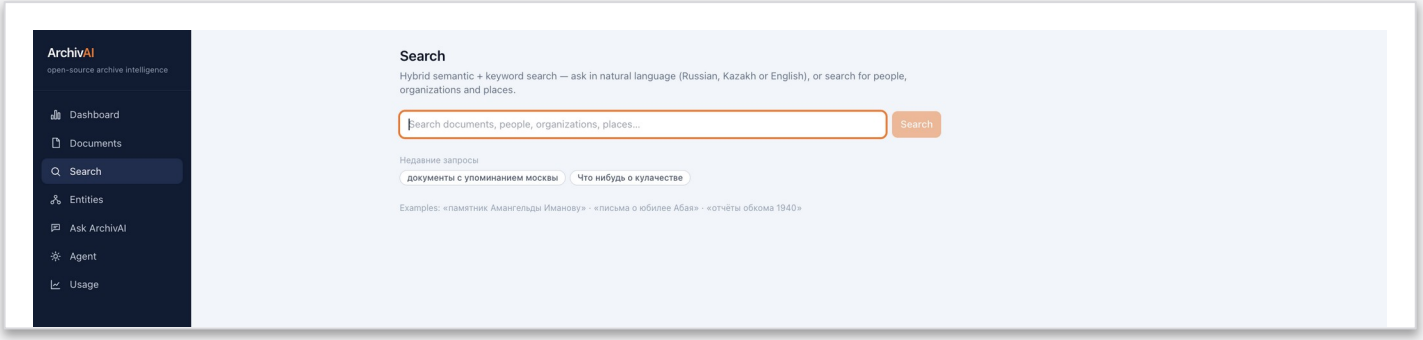
Ни одна запись не попадает в фонд как «истина» без подтверждения сотрудника.



07 СЕМАНТИЧЕСКИЙ ПОИСК

# ПОИСК ПО СМЫСЛУ, А НЕ ПО БУКВАМ




— Запрос обычными словами: «что-нибудь о кулачестве» находит приказ о ликвидации кулачества

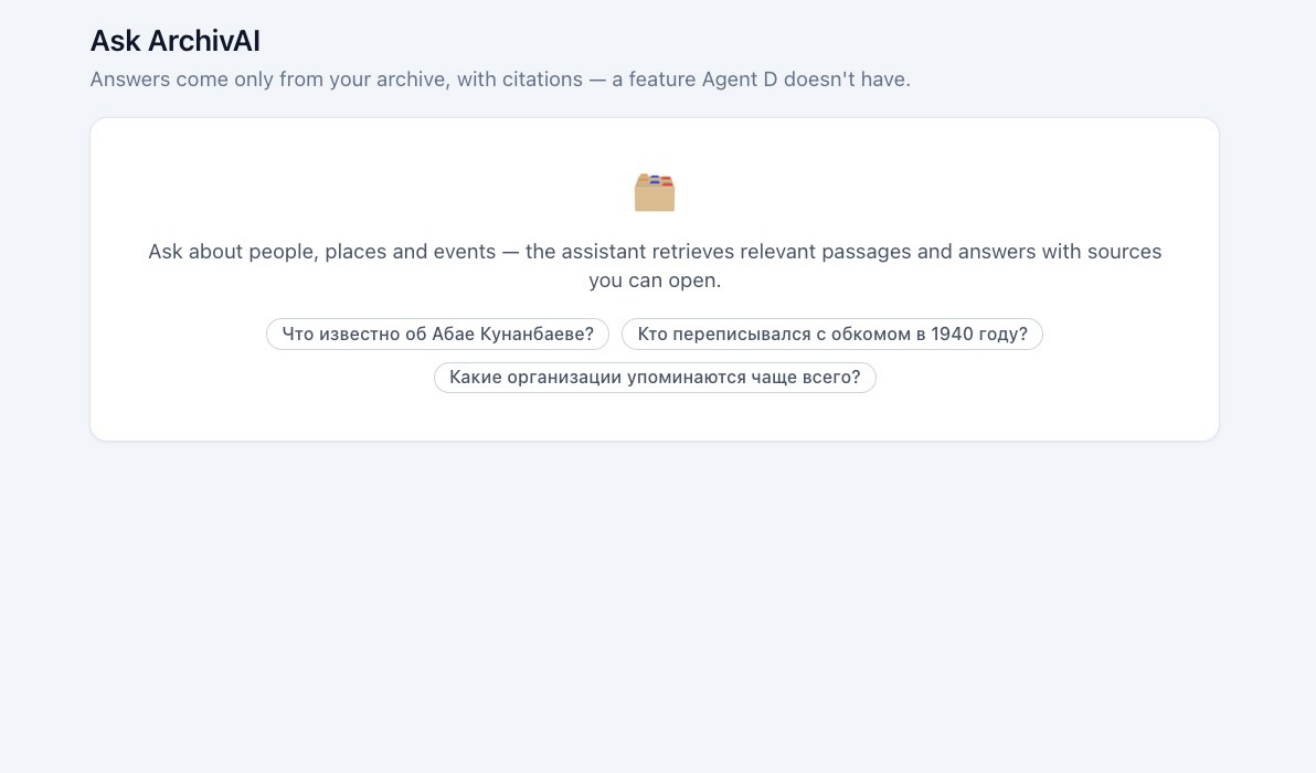
— Работает на русском и казахском, в том числе на старых написаниях

— У каждого результата — оценка релевантности; слабые совпадения отсекаются

— История запросов у каждого сотрудника своя: можно вернуться к прошлому поиску

08 АССИСТЕНТ-ИССЛЕДОВАТЕЛЬ

# ВОПРОС АРХИВУ — ОТВЕТ СО ССЫЛКАМИ




— Обычный вопрос вместо запроса: «Кто и кому писал о юбилейных мероприятиях?»

— Ответ составляется только по вашим документам — каждая мысль подкреплена ссылкой

— Клик по ссылке открывает документ-первоисточник

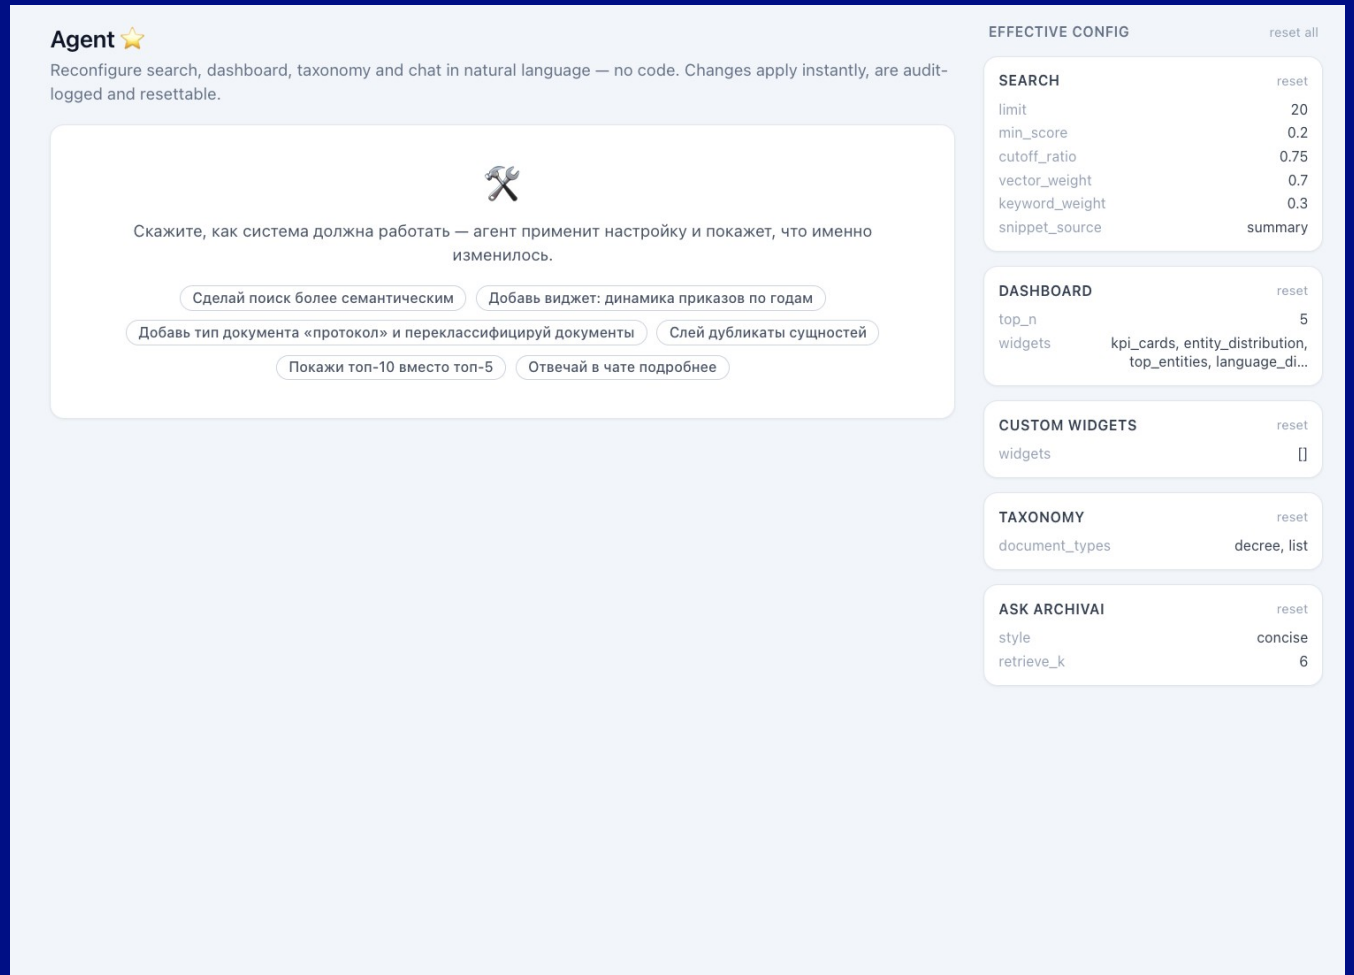
— Если ответа в фонде нет, ассистент прямо об этом говорит и не выдумывает

— Диалог помнит контекст: вопрос можно уточнять дальше

**У показанной ранее системы этого нет: её поиск возвращает только список документов**

09 АГЕНТ · ФЛАГМАН

# НАСТРОЙКА СИСТЕМЫ ОБЫЧНЫМИ СЛОВАМИ




## СКАЖИТЕ — И СИСТЕМА ПЕРЕСТРОИТСЯ:

«Добавь тип документа „протокол“ и переклассифицируй архив»

«Добавь виджет: динамика приказов по годам»

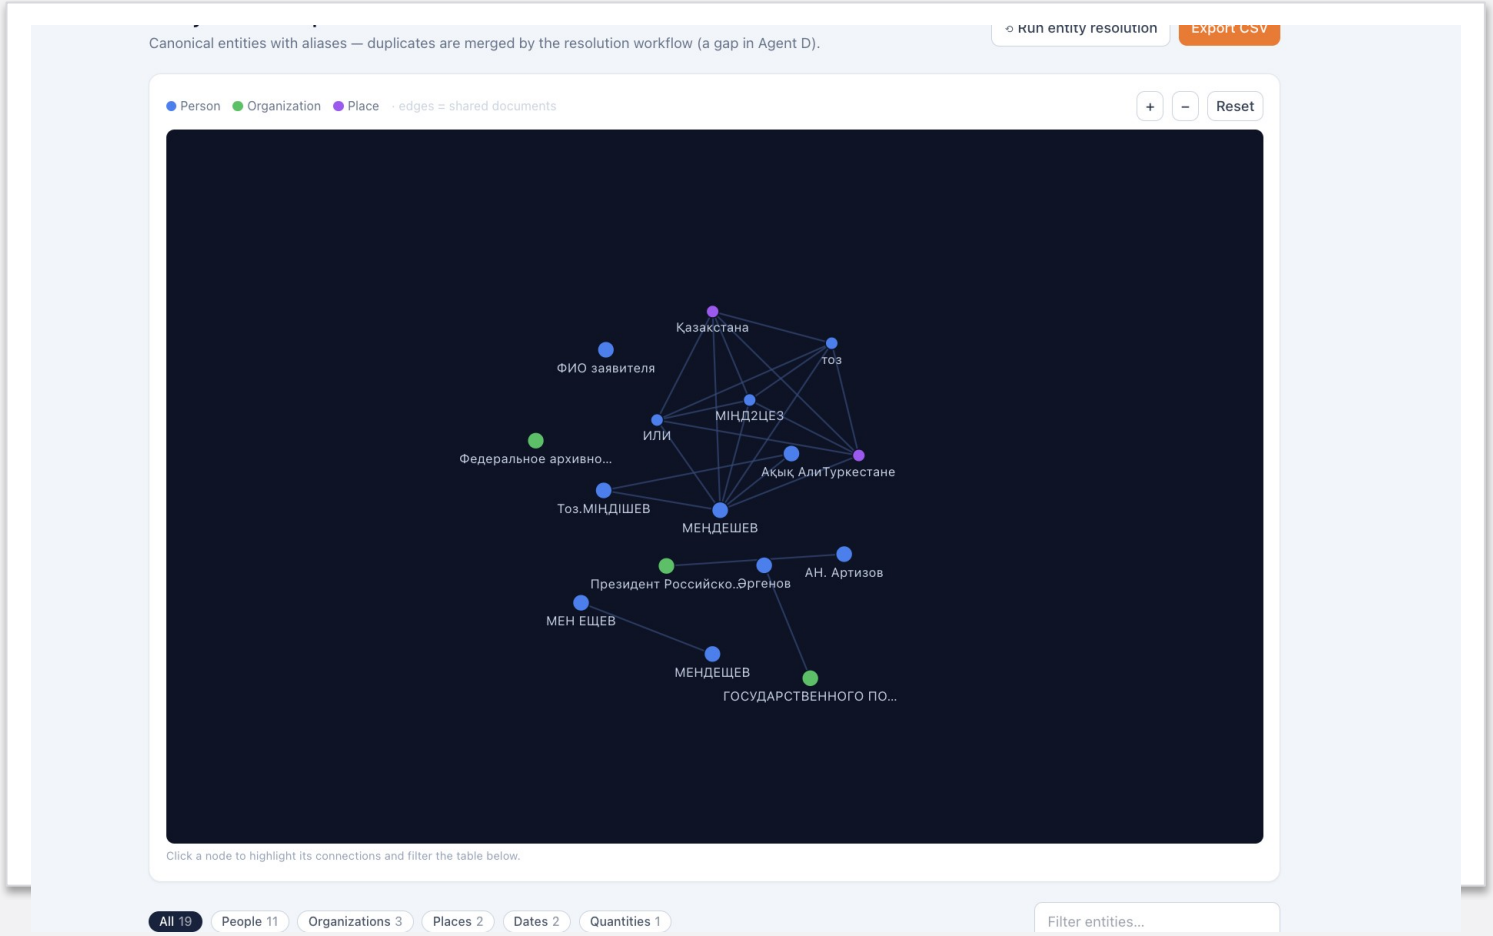
«Сделай поиск более смысловым»

«Слей дубликаты персоналий»

Безопасно по построению: модель не имеет доступа к базе — она лишь предлагает изменение. База проверяет его по правилам, применяет и записывает в журнал.

10 СУЩНОСТИ И СВЯЗИ

# СВЯЗИ ЛЮДЕЙ, ОРГАНИЗАЦИЙ И МЕСТ




— Одна персона — одна карточка: разные написания фамилии сводятся автоматически, старые сохраняются как псевдонимы

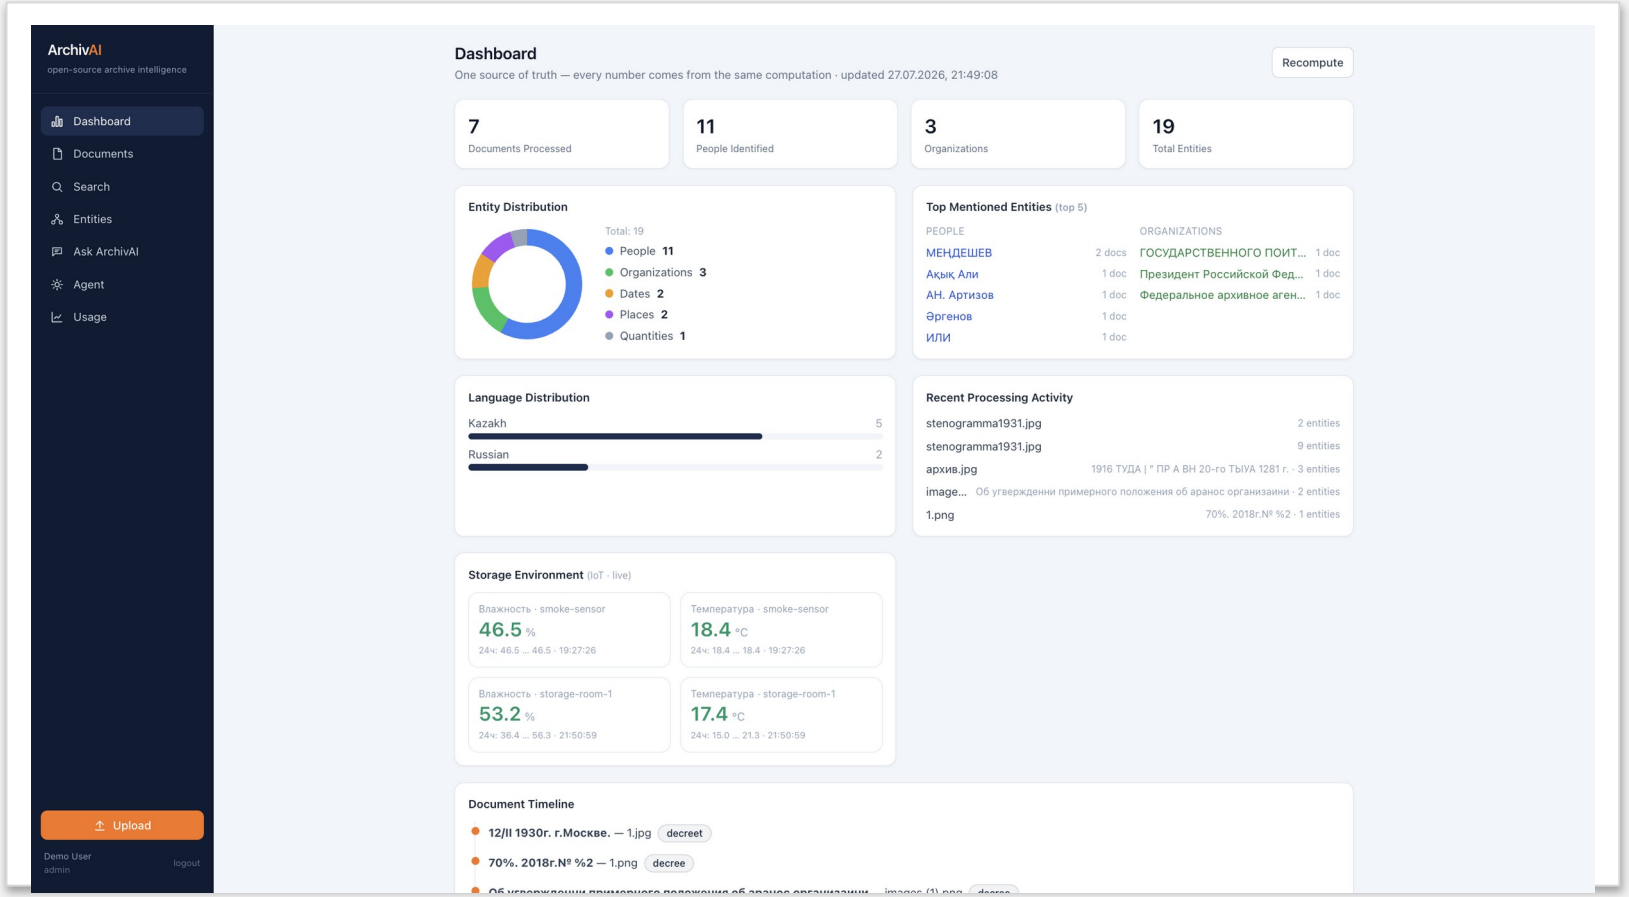
— Граф показывает, кто встречается в одних и тех же делах — связи, которые вручную не увидеть

— От сущности — переход ко всем её документам

— Выгрузка списка сущностей в CSV для отчётов и описей

**11** **АНАЛИТИКА**

# СОСТОЯНИЕ ФОНДА И ХРАНИЛИЩА




— Сколько документов обработано, сколько персоналий и организаций найдено

— Распределение по типам, языкам, хронологии фонда

— Все цифры считаются из одного источника — они не расходятся между экранами

— Датчики хранилища: температура и влажность в реальном времени, с нормами и историей за сутки

— Любой ваш датчик шлёт данные на один адрес — виджет появляется сам

12 УЧЁТ И КОНТРОЛЬ

# КТО, ЧТО И КОГДА СМОТРЕЛ

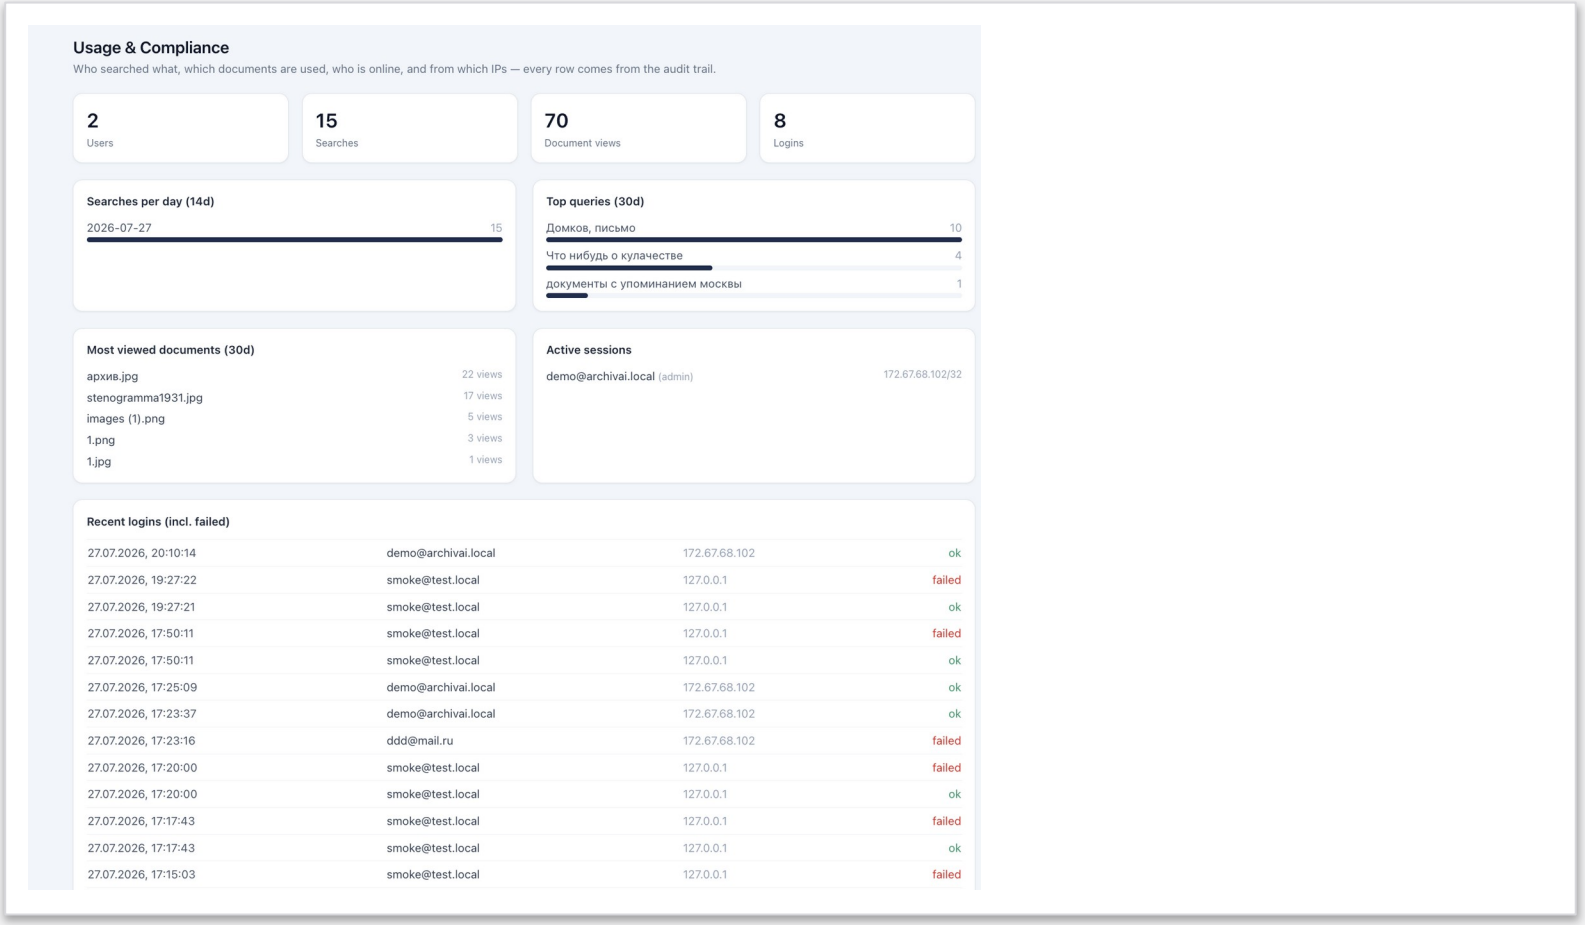
— Каждый вход — с адресом и временем, включая неудачные попытки

— Каждый поиск и каждое открытие документа фиксируются

— Видно, какие дела востребованы и кто из сотрудников сейчас работает

— Права: администратор ведёт справочники, исследователь работает с фондом

— Готово к подключению вашей единой авторизации (SSO)



13 ИНТЕГРАЦИЯ

# НУЖНЫ ТОЛЬКО ВАШЕ ХРАНИЛИЩЕ И БАЗА




### Разворачивание

один сервер у вас: локально или в частном облаке нужной юрисдикции

### Никаких внешних сервисов

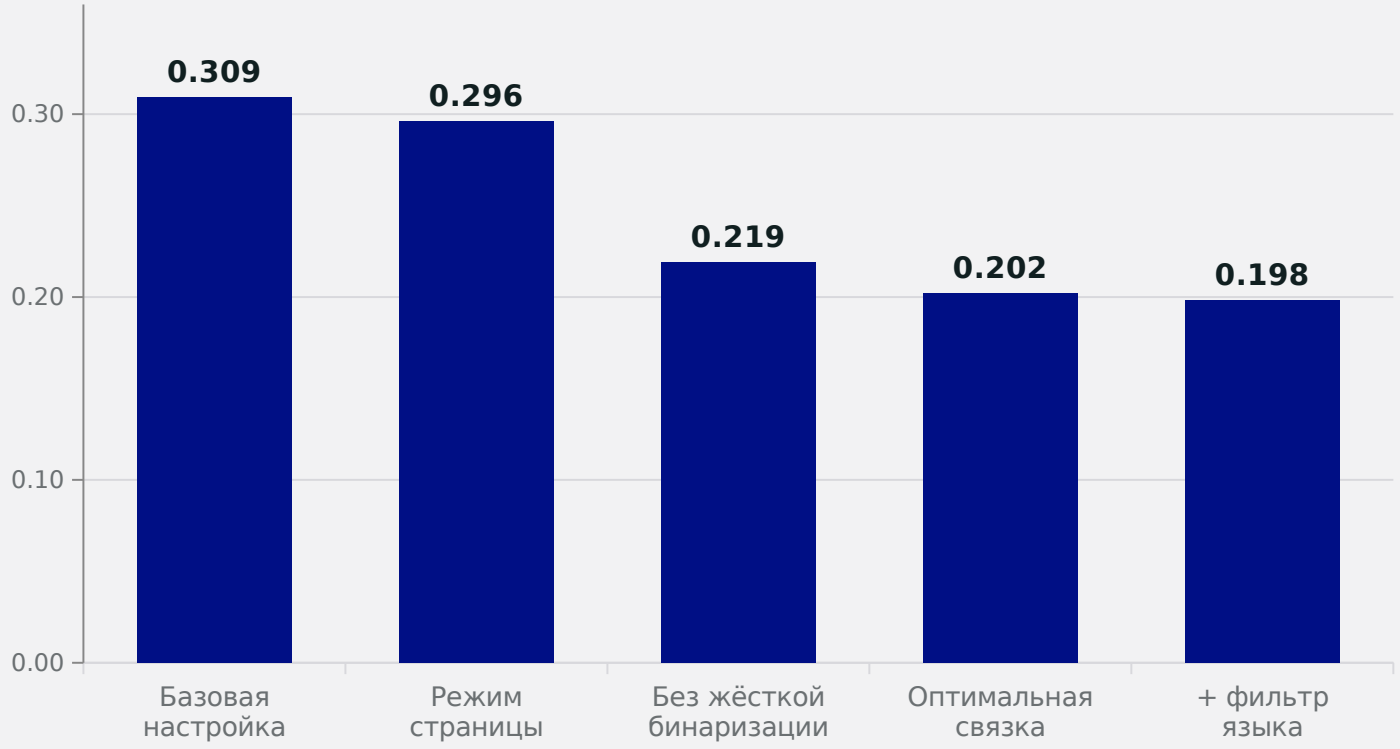
ни один документ не покидает ваш контур

### Совместимость

работает поверх существующего хранилища и старой учётной системы

14 КАЧЕСТВО РАСПОЗНАВАНИЯ

# ТОЧНОСТЬ МЫ ИЗМЕРЯЕМ, А НЕ ОБЕЩАЕМ




*Доля ошибочных символов на реальном листе фонда (стенограмма 1931 г.); меньше — лучше*

— Эталонный набор: страницы вашего фонда с выверенной вручную расшифровкой

— Настройка принимается, только если ошибка уменьшилась — не «на глаз»

— Сделано: подавление цветных правок и печатей, выравнивание перекоса, словарь эпохи, отсев ложных букв

— −36% ошибок на этом листе за один вечер работы

**ЧТО ДАСТ ДАЛЬНЕЙШИЙ РОСТ**

Качественный скан 300 dpi вместо фотографии и видеокарта на сервере: под них у системы уже есть готовый режим работы.

15 СРАВНЕНИЕ

# ЧТО ВЫ ПОЛУЧАЕТЕ СВЕРХ ПОКАЗАННОГО

| ВОЗМОЖНОСТЬ | ПОКАЗАННАЯ РАНЕЕ СИСТЕМА | ARCHIVAI |
|---|---|---|
| Ассистент с ответами по фонду и ссылками | нет | **работает** |
| Настройка обычными словами | обещано | **работает** |
| Своды персоналий без дублей | дубли остаются | **сводятся автоматически** |
| Цифры на дашборде | расходятся между экранами | **один источник** |
| Происхождение и уверенность данных | нет | **по каждому документу** |
| Измеримое качество распознавания | не показано | **эталон и метрика** |
| Модели и код | закрытые | **открытые, заменяемые** |

16 ТЕХНОЛОГИЧЕСКАЯ ОСНОВА

# ОТКРЫТАЯ, ПРОВЕРЯЕМАЯ, ВАША

01

## Открытые модели

Распознавание и извлечение — на свободных моделях. Никаких подписок и лимитов, никакой передачи документов наружу.

02

## Прозрачный конвейер

Каждый этап — видимый процесс, который можно посмотреть, повторить и изменить под ваш регламент.

03

## Надёжное хранение

Документы, тексты, сущности и поисковый индекс — в одной базе. Резервные копии — вашими стандартными средствами.

04

## Рост под нагрузку

На сервере с видеокартой точность и скорость растут без изменения системы: меняется только модель.

**Разворачивание: на вашем сервере, в вашей сети, с вашими правилами доступа.**

17 СЛЕДУЮЩИЕ ШАГИ

# КАК НАЧИНАЕМ

**1–2 НЕДЕЛИ**

## Пилот на вашем фонде

Берём 200–500 сканов, настраиваем справочник типов под ваши регламенты, показываем результат на ваших документах.

**3–4 НЕДЕЛИ**

## Внедрение в контуре

Установка на ваш сервер, подключение хранилища и учётной системы, единая авторизация, обучение сотрудников.

**ДАЛЬШЕ**

## Развитие

Дообучение на ваших проверенных документах, вырезка подписей и печатей, датчики хранилища, отчётность под ваши формы.

**Система уже работает: сегодня мы показываем не прототип, а готовый контур.**