ArchivAI

Искусственный интеллект для исторического архива

Сканы → распознанный текст, структурированные поля, связи между людьми и организациями, семантический поиск и проверка человеком.
Полностью на открытых моделях, на вашем оборудовании.

Открытый код | On-premise | Русский + қазақша | Без облаков и подписок

ЗАДАЧА

Что мешает работать с фондом сегодня

1

Документы не ищутся

Скан — это картинка. Найти дело можно только по описи и памяти сотрудника.

2

Связи не видны

Кто с кем переписывался, где упоминается человек — собирается вручную, месяцами.

3

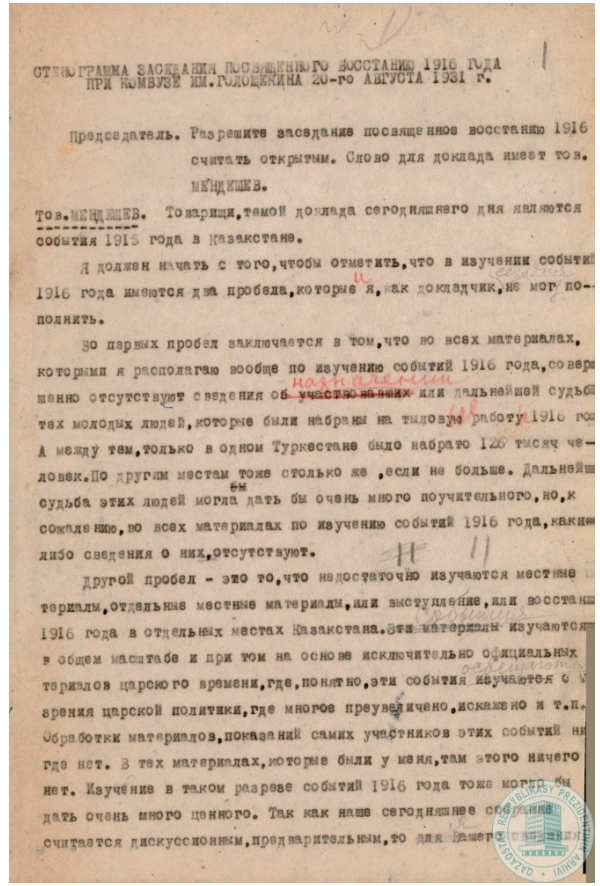
Ручная опись

Тип, дата, отправитель, получатель, персоналии — всё вносится руками.

4

Данные должны остаться у вас

Облачные сервисы и передача фонда наружу — неприемлемы.



СТЕНОГРАММА ЗАСЕДАНИЯ ПОСВЯЩЕННОГО ВОССТАНИЮ 1916 ГОДА
ПРИ КОМВУЗЕ ИМ.ГОЛОЩЕКИНА 20-го АВГУСТА 1931 Г.

Председатель. Разрешите заседание посвященное восстанию 1916 считать открытым. Слово для доклада имеет тов. МЕНДЕШЕВ.

Тов.МЕНДЕШЕВ. Товарищи,темой доклада сегодняшнего дня являются события 1916 года в Казакстане.

Я должен начать с того,чтобы отметить,что в изучении событий 1916 года имеются два пробела,которые я,как докладчик,не мог по-полнить.

Во первых пробел заключается в том,что во всех материалах, которыми я располагаю вообще по изучению событий 1916 года,совер-шенно отсутствуют сведения об участии них или дальнейшей судьбе тех молодых людей,которые были набраны на тыловую работу 1916 го А между тем,только в одном Туркестане было набрато 125 тысяч че-ловек.По другим местам тоже столько же ,если не больше. Дальнейш судьба этих людей могла дать бы очень много поучительного,но,к сожалению,во всех материалах по изучению событий 1916 года,каки либо сведения о них,отсутствуют.

Другой пробел - это то,что недостаточно изучаются местные териалы,отдельные местные материалы,или выступление,или восстани 1916 года в отдельных местах Казакстана.Эти материалы изучаются в общем масштабе и при том на основе исключительно официальных териалов царского времени,где,понятно,эти события изучаются с зрения царской политики,где многое преувеличено,искажено и т.п. Обработки материалов,показаний самих участников этих событий не где нет. В тех материалах,которые были у меня,там этого ничего нет. Изучение в таком разрезе событий 1916 года тоже могло бы дать очень много ценного. Так как наше сегодняшнее со считается дискуссионным,предварительным,то для нашего

Типовой лист фонда: машинопись, правки от руки, печать, пожелтевшая бумага

КАК ЭТО РАБОТАЕТ

От скана до знания — за один проход

1 **Приём**
загрузка или забор из вашего хранилища

→

2 **Распознавание**
печатный и рукописный текст, RU + KZ

→

3 **Извлечение**
тип, дата, отправитель, получатель, резюме

→

4 **Сущности**
люди, организации, места, даты, количества

→

5 **Индексация**
поиск по смыслу, а не по буквам

→

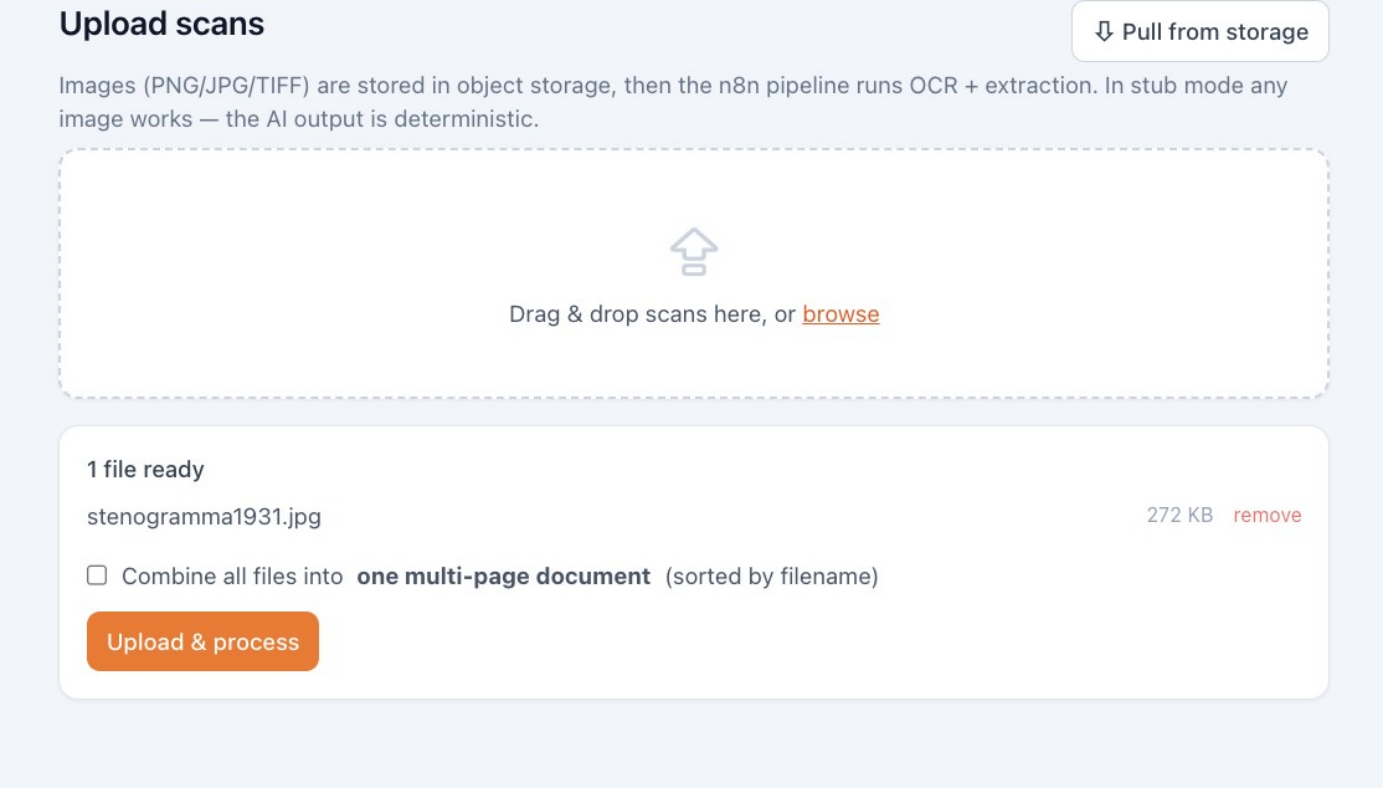
6 **Проверка**
правка человеком и статус «проверено»

Каждый этап — отдельный видимый процесс

Модель распознавания, правила извлечения, набор типов документов можно заменить или дополнить без переписывания системы. Ничего не «зашито» в чёрный ящик: любой шаг открывается, повторяется и настраивается под ваш фонд.

ПРИЁМ ДОКУМЕНТОВ

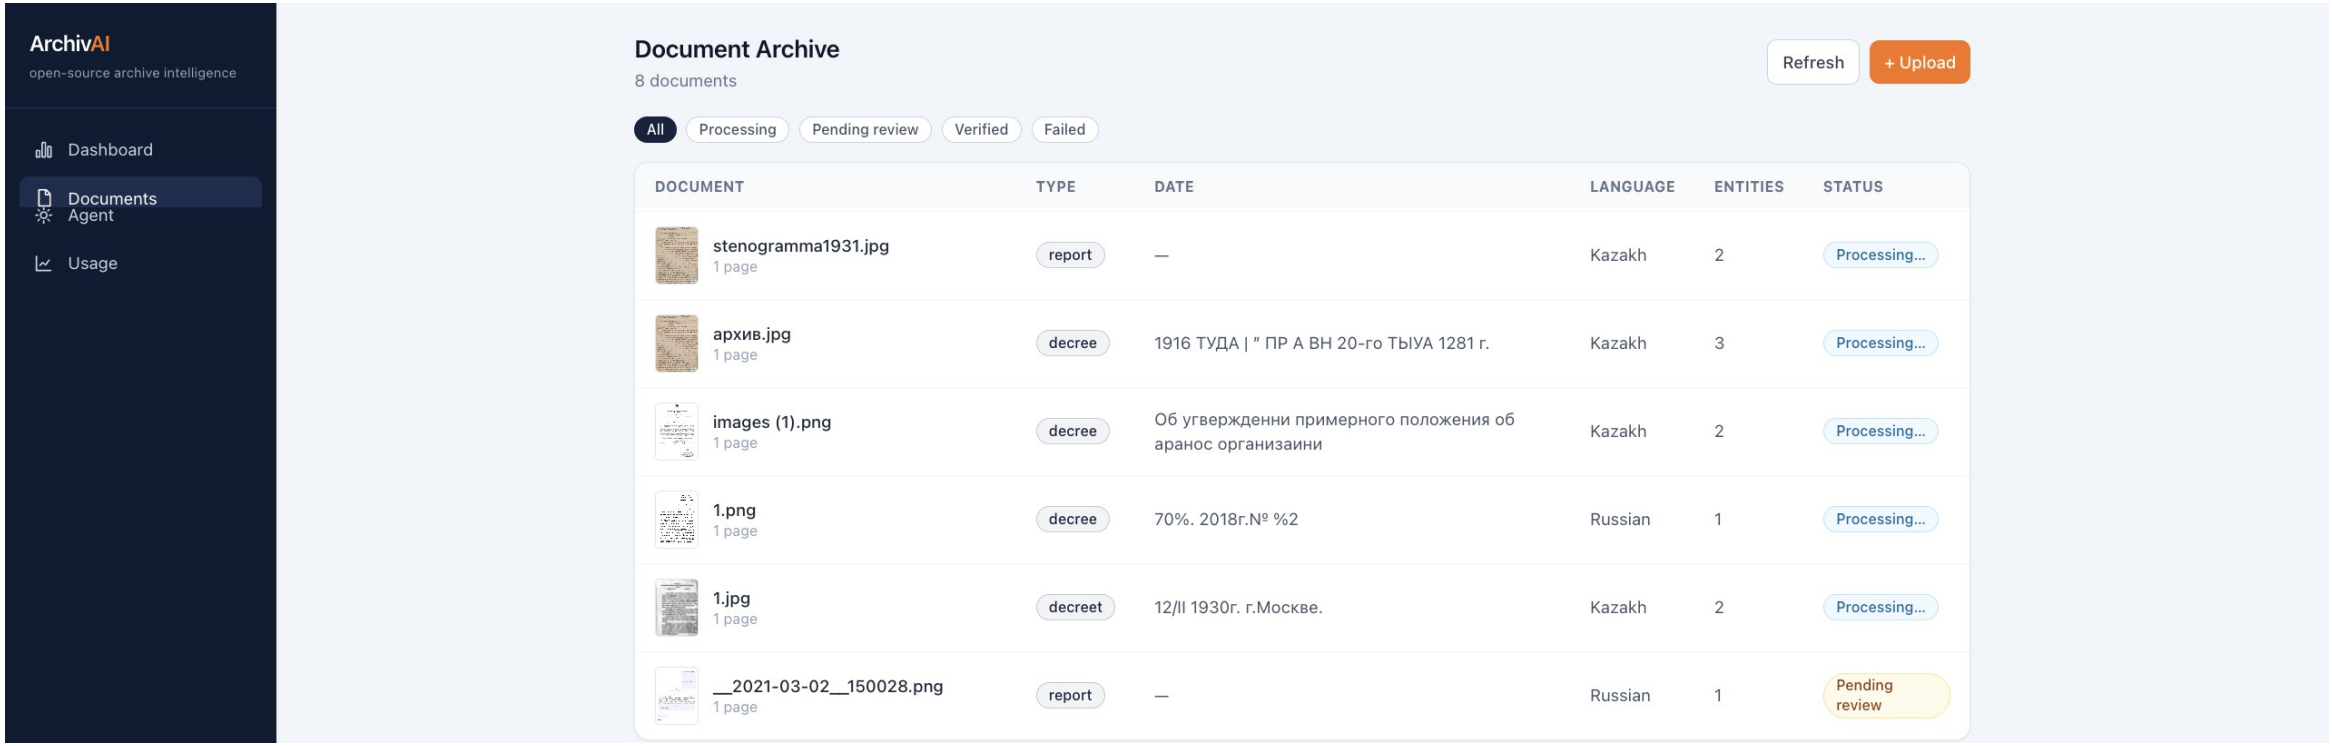
Загрузка вручную — и забор пачками из хранилища



- Перетащите сканы в окно — или соберите многостраничное дело из нескольких файлов
- Кнопка «Забрать из хранилища»: система сама берёт новые файлы — 50–100+ документов за раз
- Автоматический забор каждые 5 минут: положили сканы в папку — они появились в архиве обработанными
- Повторная заливка не создаёт дублей: уже обработанные файлы пропускаются

АРХИВ ДОКУМЕНТОВ

Весь фонд — в одной таблице



Статусы обработки

обрабатывается · на проверке · проверено · ошибка

Фильтры

по типу, языку, статусу, дате документа

Миниатюры

виден сам скан, а не только имя файла

КАРТОЧКА ДОКУМЕНТА

Скан слева — извлечённые данные справа

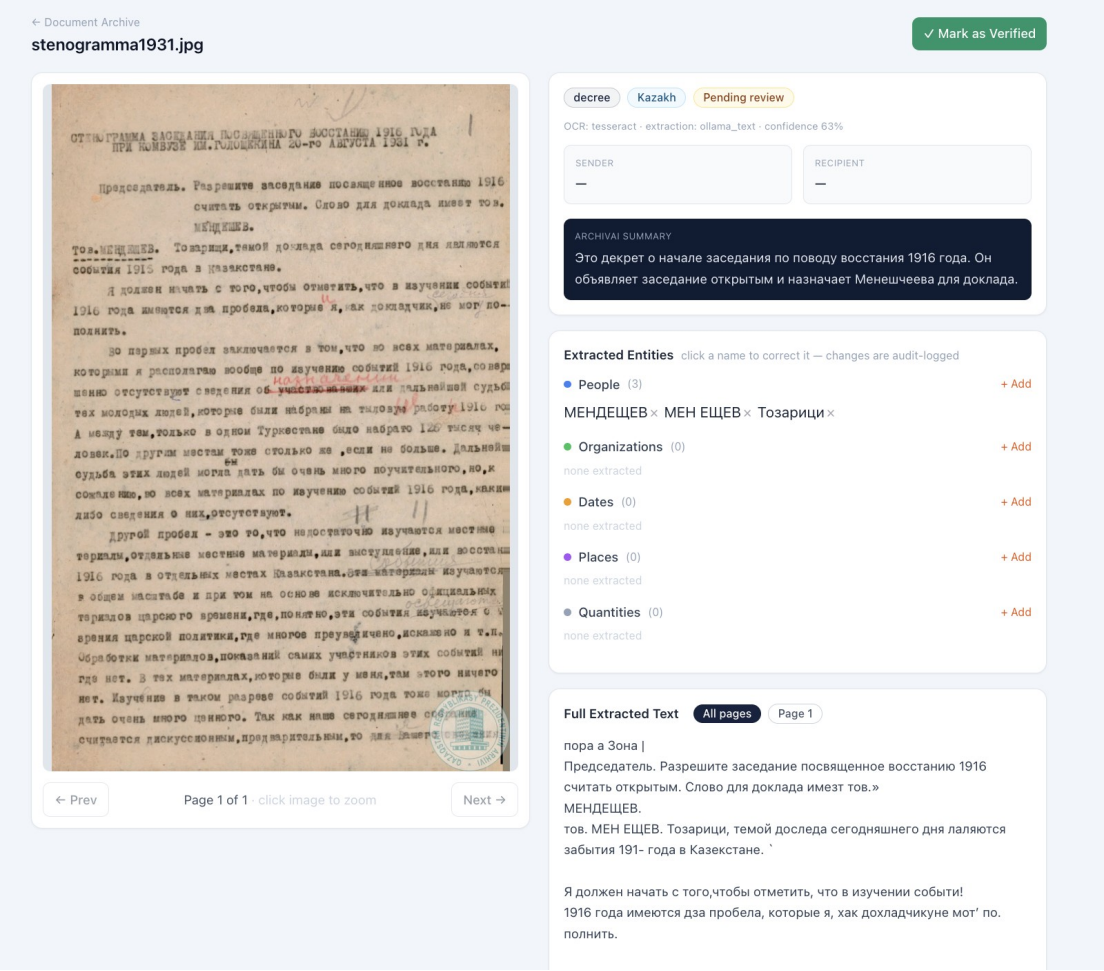


- **Тип, дата, язык**
  классификация по вашему справочнику типов
- **Отправитель и получатель**
  с должностью и ролью, если они есть в тексте
- **Резюме документа**
  2–4 предложения на русском: суть дела без чтения листа
- **Сущности по 5 категориям**
  люди · организации · места · даты · количества
- **Полный текст**
  постранично и целиком, с источником и уверенностью

ПРОВЕРКА И ДОВЕРИЕ

Последнее слово — за архивистом

- Любую сущность можно исправить прямо в карточке: опечатка в фамилии, пропущенная организация
- Кнопка «Проверено» переводит документ в доверенный статус
- Каждая правка записывается в журнал: кто, что и когда изменил
- Проверенные документы защищены: массовая переобработка их не трогает
- Исправления накапливаются как эталон — на них система дообучается под ваш фонд

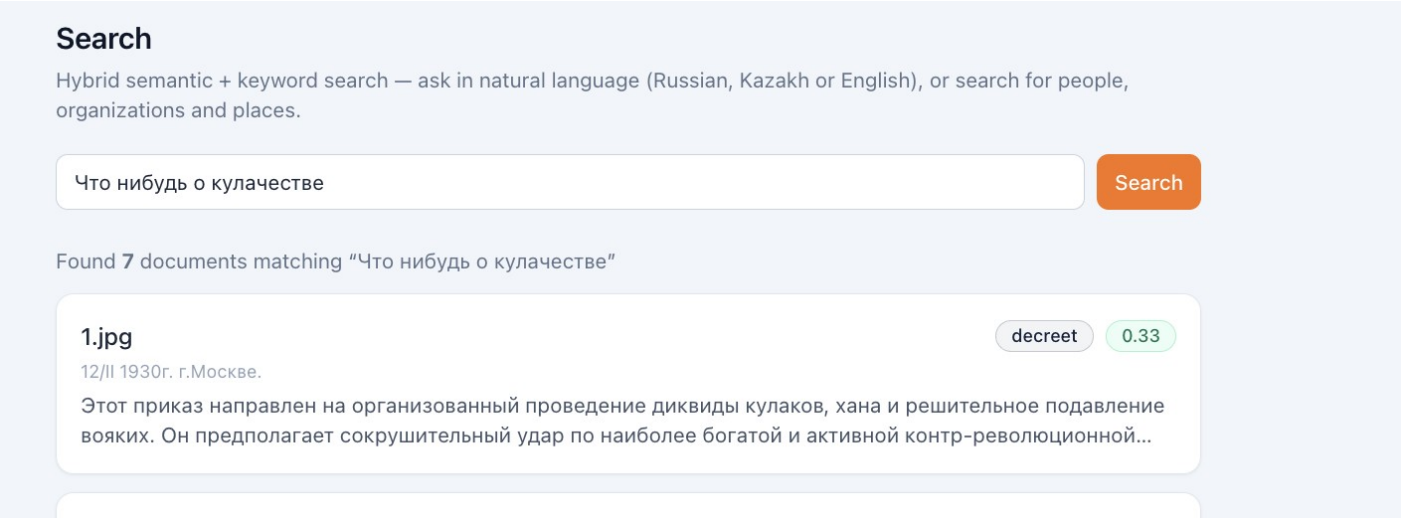


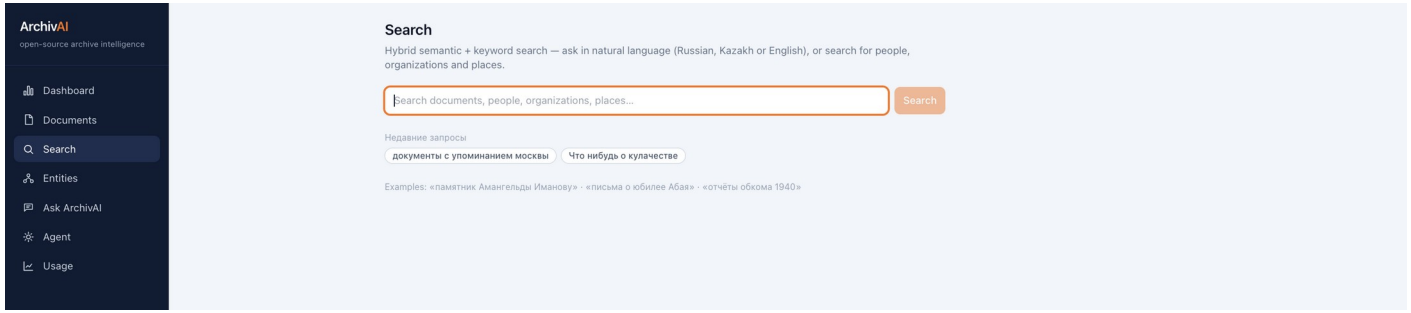
ИИ предлагает — человек утверждает

Ни одна запись не попадает в фонд как «истина» без подтверждения сотрудника.

СЕМАНТИЧЕСКИЙ ПОИСК

Поиск по смыслу, а не по буквам

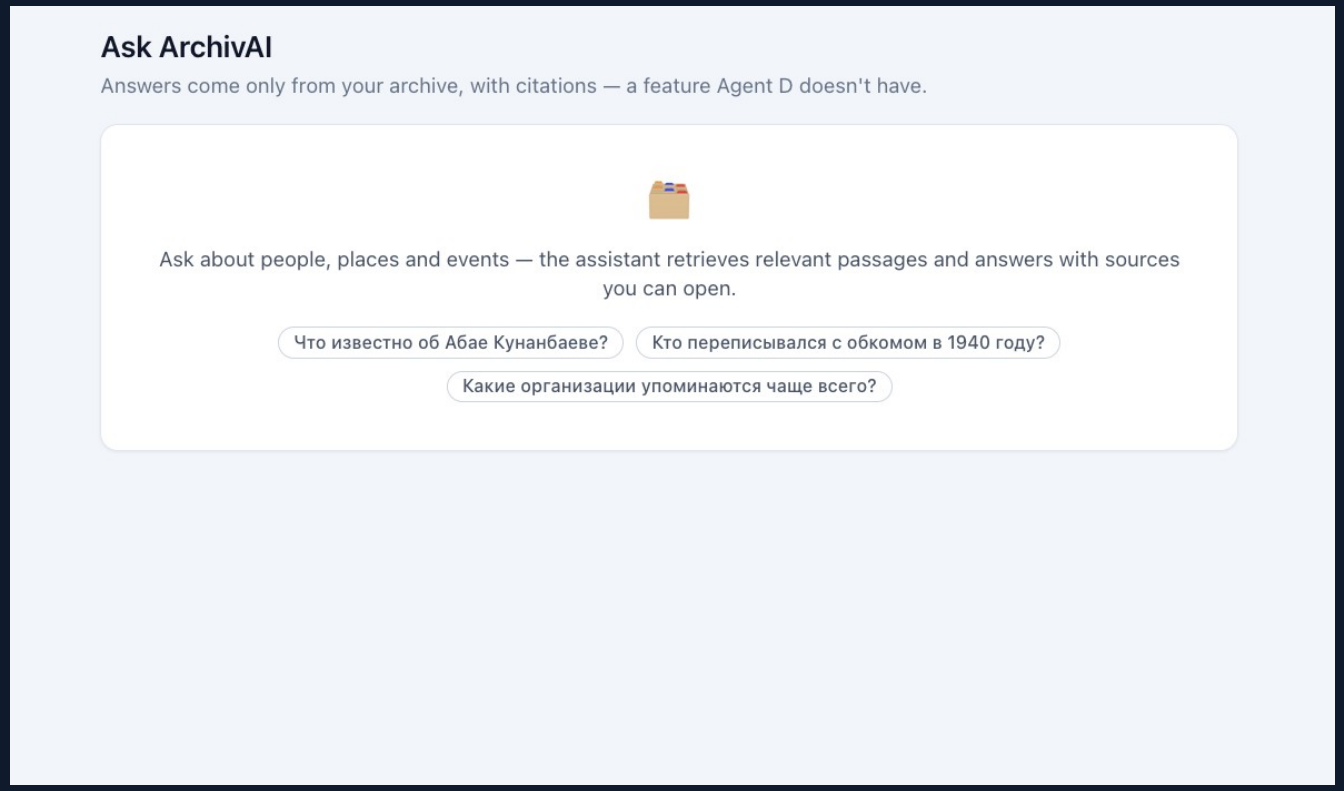




- Запрос обычными словами: «что-нибудь о кулачестве» находит приказ о ликвидации кулачества
- Работает на русском и казахском, в том числе на старых написаниях
- У каждого результата — оценка релевантности; слабые совпадения отсекаются
- История запросов у каждого сотрудника своя: можно вернуться к прошлому поиску

АССИСТЕНТ-ИССЛЕДОВАТЕЛЬ

Вопрос архиву — ответ со ссылками на дела

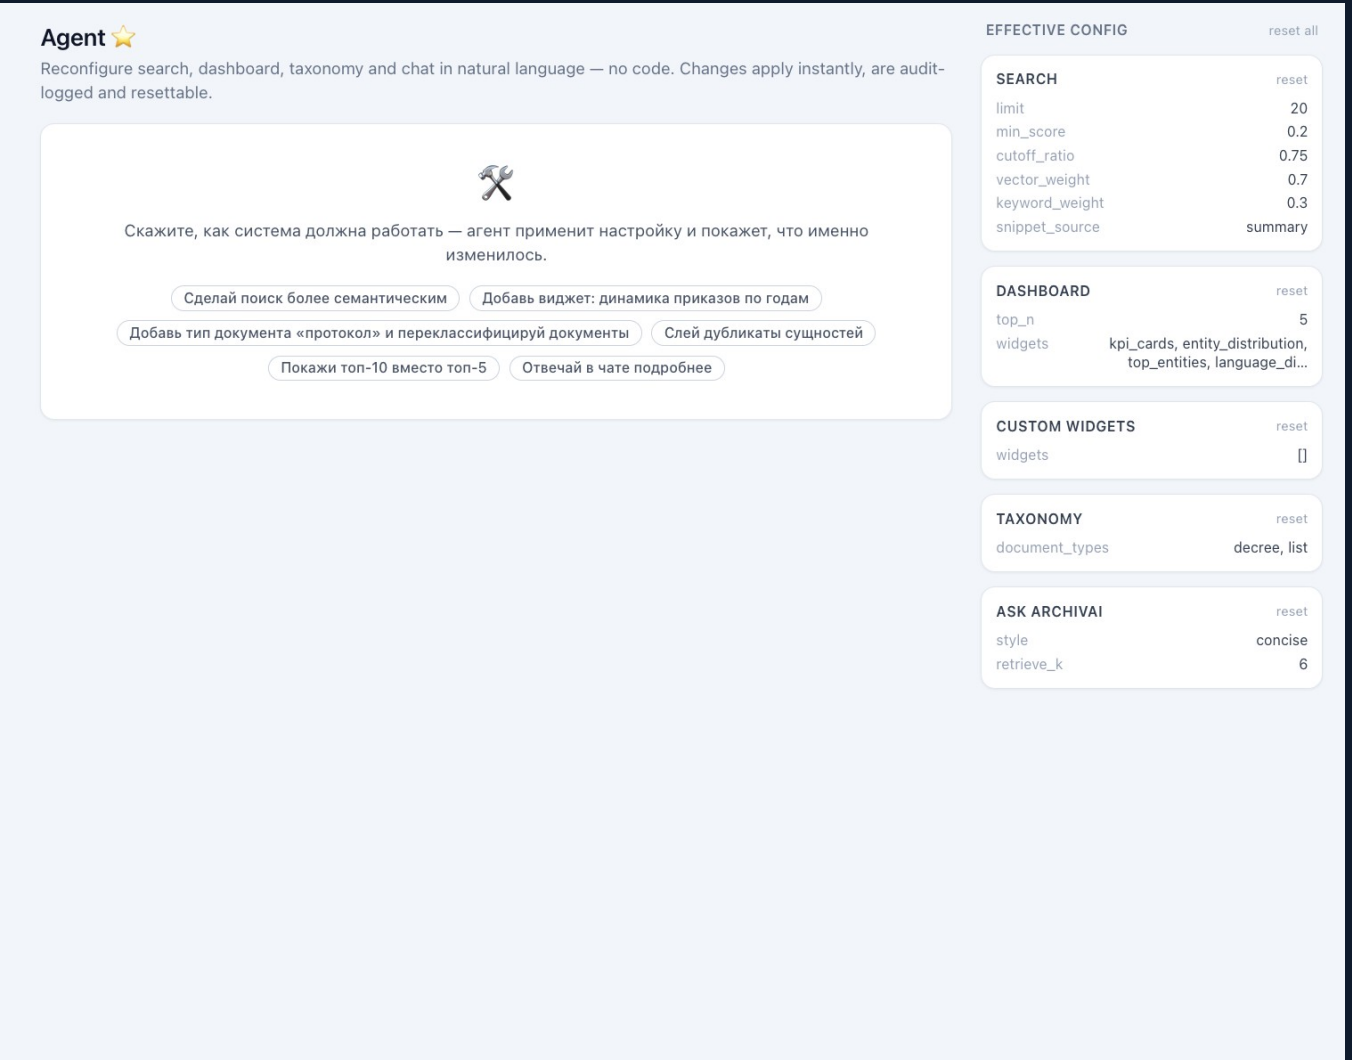


- Обычный вопрос вместо запроса: «Кто и кому писал о юбилейных мероприятиях?»
- Ответ составляется только по вашим документам — каждая мысль подкреплена ссылкой
- Клик по ссылке открывает документ-первоисточник
- Если ответа в фонде нет, ассистент прямо об этом говорит и не выдумывает
- Диалог помнит контекст: вопрос можно уточнять дальше

У показанной ранее системы этого нет:
её поиск возвращает только список документов

АГЕНТ • ФЛАГМАН

Настройка системы обычными словами



Скажите — и система перестроится:

«Добавь тип документа „протокол“ и переклассифицируй архив»

«Добавь виджет: динамика приказов по годам»

«Сделай поиск более смысловым»

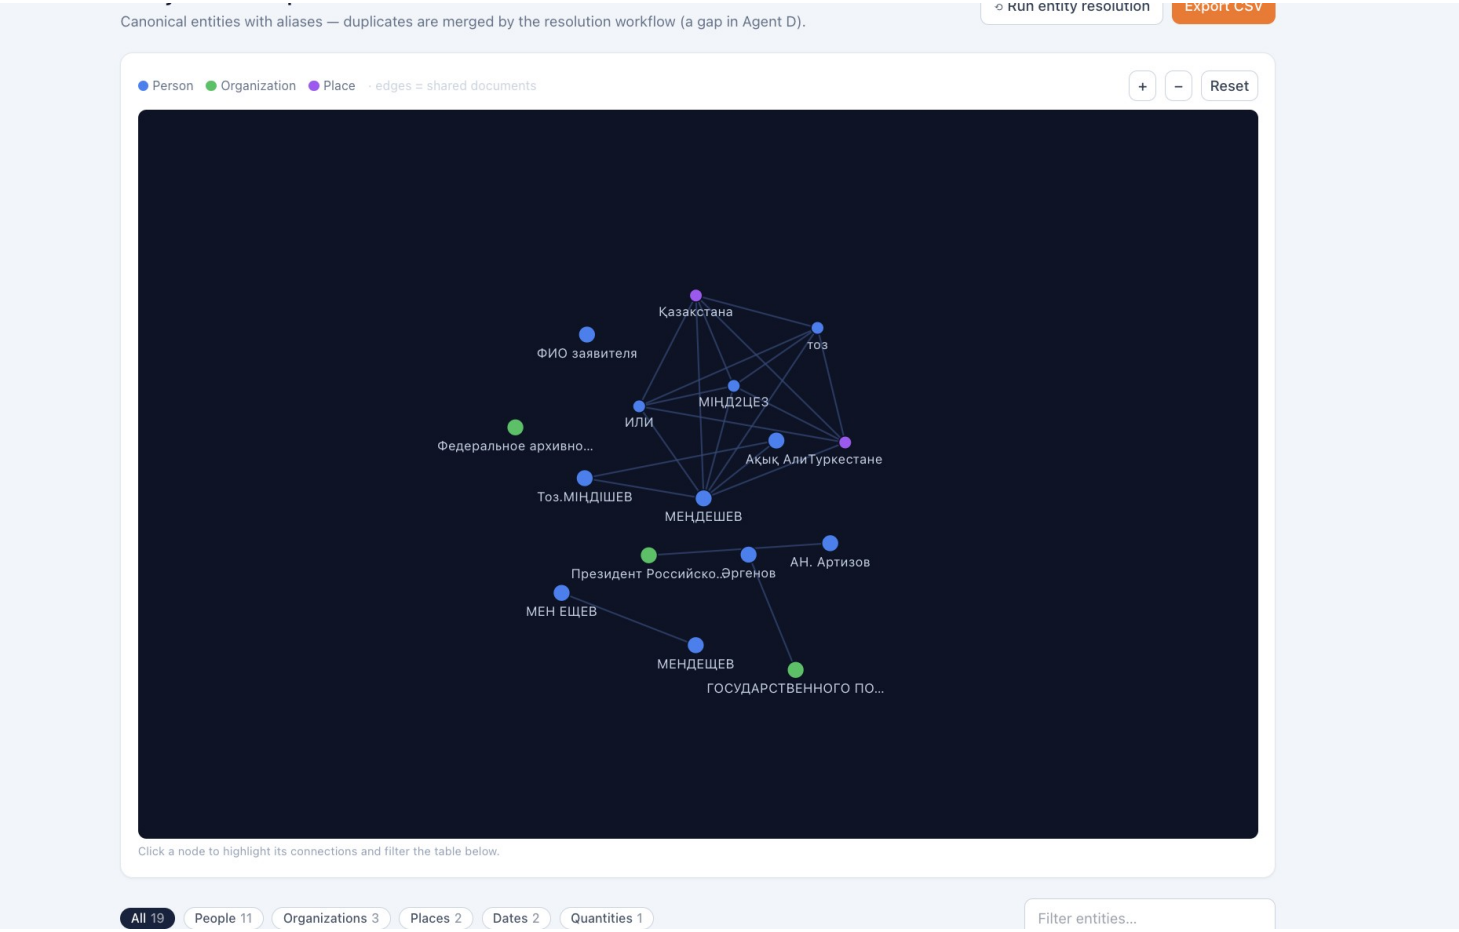
«Слей дубликаты персоналий»

Безопасно по построению

Модель не имеет доступа к базе: она лишь предлагает изменение. База проверяет его по правилам, применяет и записывает в журнал. Любую настройку можно откатить одной кнопкой.

СУЩНОСТИ И СВЯЗИ

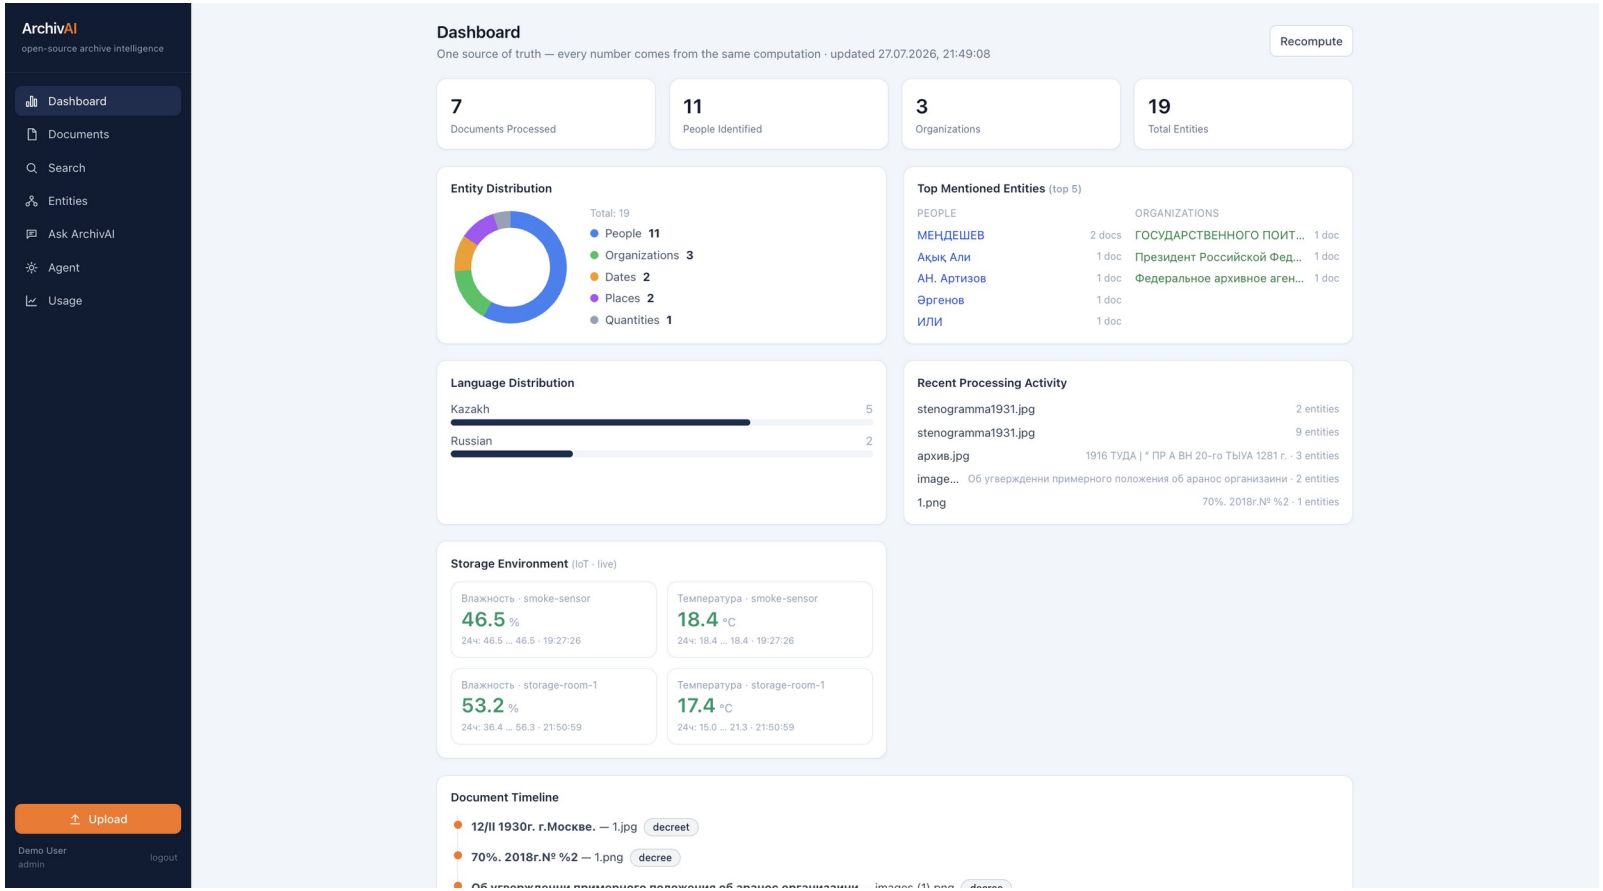
Люди, организации и места — связаны между делами



- Одна персона — одна карточка: разные написания фамилии сводятся автоматически, старые сохраняются как псевдонимы
- Граф показывает, кто встречается в одних и тех же делах — связи, которые вручную не увидеть
- От сущности — переход ко всем её документам
- Выгрузка списка сущностей в CSV для отчётов и описей

АНАЛИТИКА

Состояние фонда — и состояние хранилища

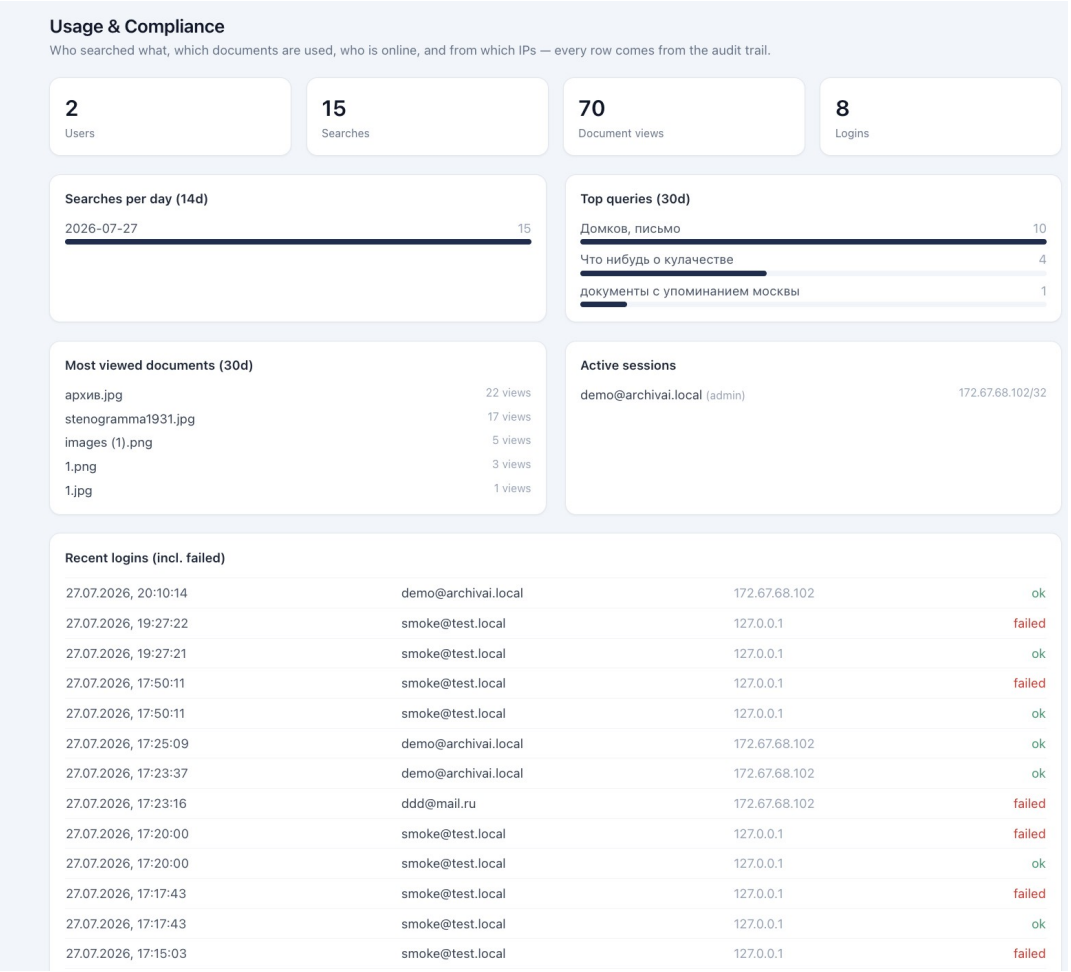


- Сколько документов обработано, сколько персоналий и организаций найдено
- Распределение по типам, языкам, хронологии фонда
- Все цифры считаются из одного источника — они не расходятся между экранами
- Датчики хранилища: температура и влажность в реальном времени, с нормами и историей за сутки
- Любой ваш датчик шлёт данные на один адрес — виджет появляется сам

УЧЁТ И КОНТРОЛЬ

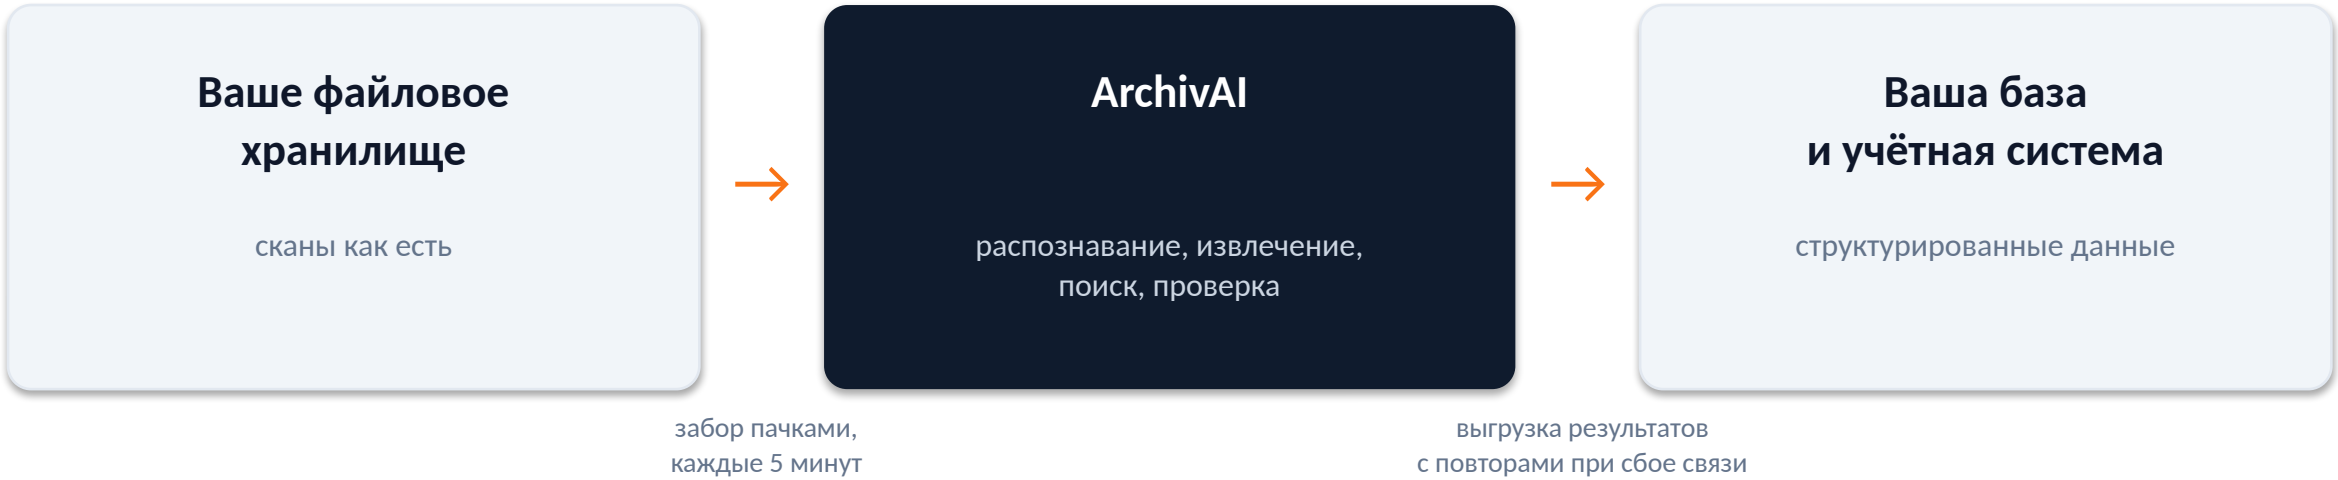
Кто, что и когда смотрел

- Каждый вход — с адресом и временем, включая неудачные попытки
- Каждый поиск и каждое открытие документа фиксируются
- Видно, какие дела востребованы и кто из сотрудников сейчас работает
- Права: администратор ведёт справочники, исследователь работает с фондом
- Готово к подключению вашей единой авторизации (SSO)



ИНТЕГРАЦИЯ

Системе нужны только ваше хранилище и ваша база



Разворачивание

один сервер у вас: локально или в частном облаке нужной юрисдикции

Никаких внешних сервисов

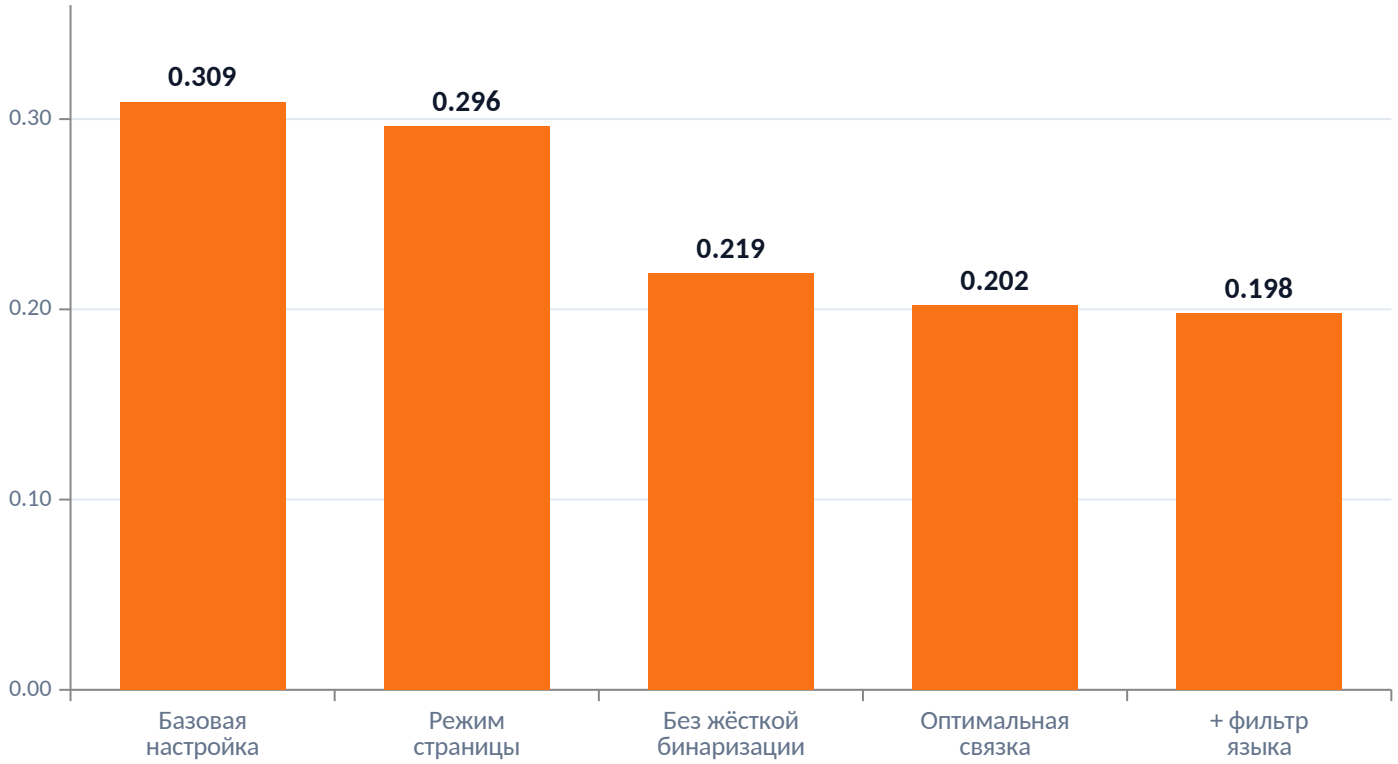
ни один документ не покидает ваш контур

Совместимость

работает поверх существующего хранилища и старой учётной системы

КАЧЕСТВО РАСПОЗНАВАНИЯ

Мы не обещаем точность — мы её измеряем



Доля ошибочных символов на реальном листе фонда (стенограмма 1931 г.); меньше — лучше

- Эталонный набор: страницы вашего фонда с выверенной вручную расшифровкой
- Настройка принимается, только если ошибка уменьшилась — не «на глаз»
- Сделано: подавление цветных правок и печатей, выравнивание перекоса, словарь эпохи, отсев ложных букв
- −36% ошибок на этом листе за один вечер работы

Что даст дальнейший рост

Качественный скан 300 dpi вместо фотографии и видеокарта на сервере: под них у системы уже есть готовый режим работы.

СРАВНЕНИЕ

Что вы получаете сверх показанного ранее

Возможность	Показанная ранее система	ArchivAI
Ассистент с ответами по фонду и ссылками	нет	**работает**
Настройка обычными словами	обещано	**работает**
Своды персоналий без дублей	дубли остаются	**сводятся автоматически**
Цифры на дашборде	расходятся между экранами	**один источник**
Происхождение и уверенность данных	нет	**по каждому документу**
Измеримое качество распознавания	не показано	**эталон и метрика**
Модели и код	закрытые	**открытые, заменяемые**

ТЕХНОЛОГИЧЕСКАЯ ОСНОВА

Открытая, проверяемая, ваша

1

Открытые модели

Распознавание и извлечение — на свободных моделях. Никаких подписок и лимитов, никакой передачи документов наружу.

2

Прозрачный конвейер

Каждый этап — видимый процесс, который можно посмотреть, повторить и изменить под ваш регламент.

3

Надёжное хранение

Документы, тексты, сущности и поисковый индекс — в одной базе. Резервные копии — вашими стандартными средствами.

4

Рост под нагрузку

На сервере с видеокартой точность и скорость растут без изменения системы: меняется только модель.

Разворачивание: на вашем сервере, в вашей сети, с вашими правилами доступа.

СЛЕДУЮЩИЕ ШАГИ

Как начинаем

1–2 недели

Пилот на вашем фонде

Берём 200–500 сканов, настраиваем справочник типов под ваши регламенты, показываем результат на ваших документах.

3–4 недели

Внедрение в контуре

Установка на ваш сервер, подключение хранилища и учётной системы, единая авторизация, обучение сотрудников.

дальше

Развитие

Дообучение на ваших проверенных документах, вырезка подписей и печатей, датчики хранилища, отчётность под ваши формы.

Система уже работает: сегодня мы показываем не прототип, а готовый контур.